Казанский федеральный
УНИВЕРСИТЕТ

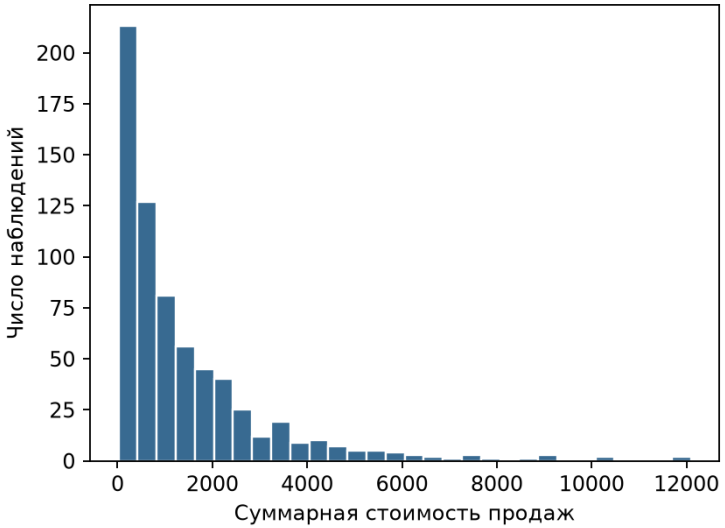
Анализ данных розничной торговли с помощью множественной регрессии

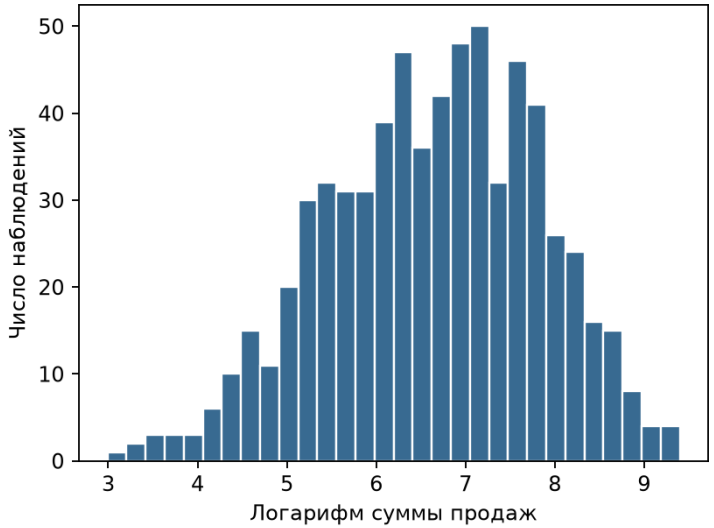
Какие факторы связаны с суммой продаж
и помогает ли расширение модели предсказывать её?

Кибардин Максим Олегович · группа 05-308
Научный руководитель: Р. Ф. Салимов · Казань, 2026

1. Проверены данные и уточнён смысл отклика

676 строк · 52 товара · 9 категорий · январь 2017 — август 2018





Что проверено

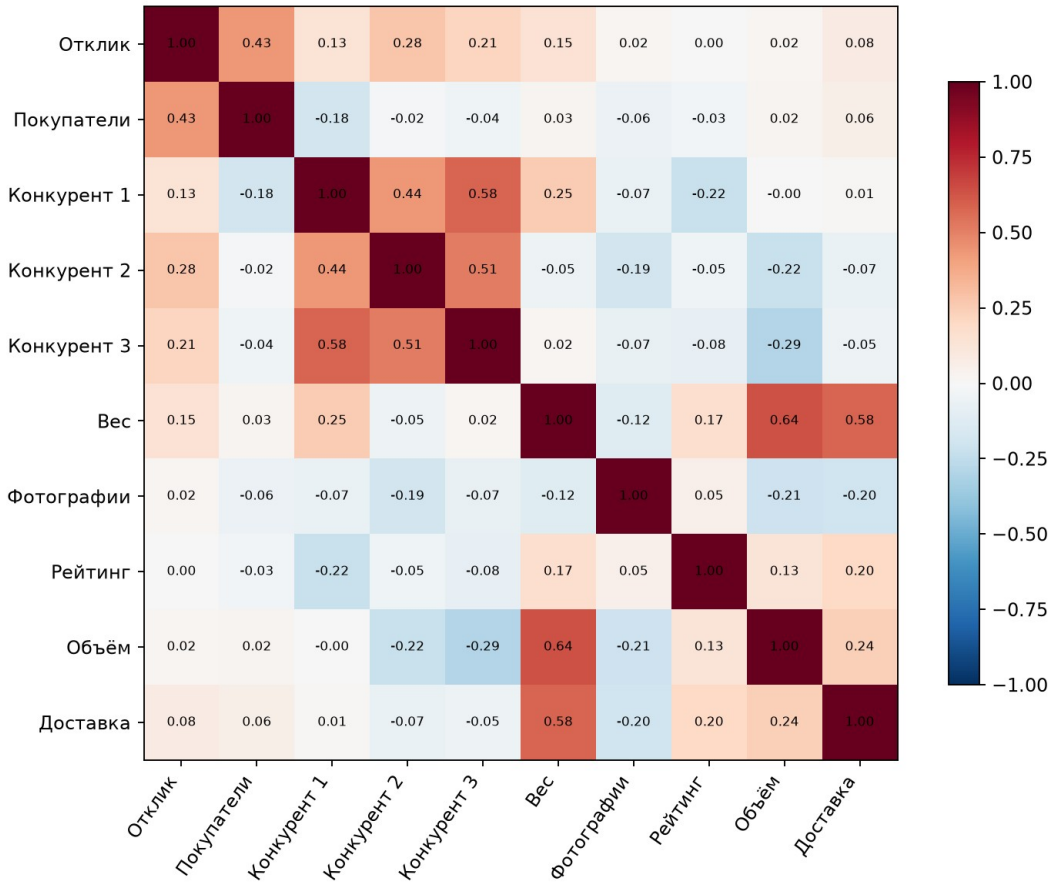
Пропуски и дубли: 0.
Проверены даты
и ключ «товар–месяц».

Все строки сохранены.

total_price ≈ цена единицы × количество → изучаем сумму продаж за месяц.

Логарифм сжимает правый хвост и позволяет описывать относительные связи.

2. Исследованы связи и выбран набор факторов



Что показал предварительный анализ

Покупатели и сумма продаж: r = 0,43.
Вес и объём: r = 0,64.
Парные связи требуют проверки в общей модели.

Что включено в исследование

9 числовых факторов:
покупатели; 3 цены конкурентов;
вес, объём, фотографии, рейтинг, доставка.
Дополнительно — категория товара.

Цена единицы и количество исключены:
они почти арифметически восстанавливают отклик.

Тепловая карта описывает парные корреляции, а не причинные эффекты и не значимость коэффициентов.

3. Сравнены три варианта множественной регрессии

Одна выборка и один отклик. Меняем только состав объясняющих факторов.

Вариант	Что добавлено	R^2 скорр.
Базовая (M1)	Покупатели, 3 цены, вес, фото	0,305
С категориями (M2)	8 индикаторов категории	0,361
Расширенная (M3)	Рейтинг, объём и доставка	0,379

Категория улучшила подгонку: 0,305 → 0,361.
Три новых признака повысили её до 0,379.

$$\ln(Y) = b_0 + b_1x_1 + \ldots + b_9x_9 + \text{эффекты категории} + \varepsilon$$

Y — сумма продаж; b — коэффициенты; x — факторы (шкалы на слайде 5); ε — ошибка.

Оценивание — МНК; ошибки по товару. R^2 описывает подгонку; проверка предсказаний — слайд 7.

4. Проверено, какие связи сохраняются в общей модели

Фактор	Коэфф.	p Холма
ln покупателей	**0,686**	**< 0,001**
ln цены конкурента 1	0,195	0,728
ln цены конкурента 2	0,252	1,000
ln цены конкурента 3	0,447	0,211
ln веса	**0,314**	**0,049**
Фотографии	0,126	0,211
Рейтинг	-0,029	1,000
ln объёма	0,335	0,200
Доставка	≈ 0	1,000

Цены конкурентов: совместная связь есть

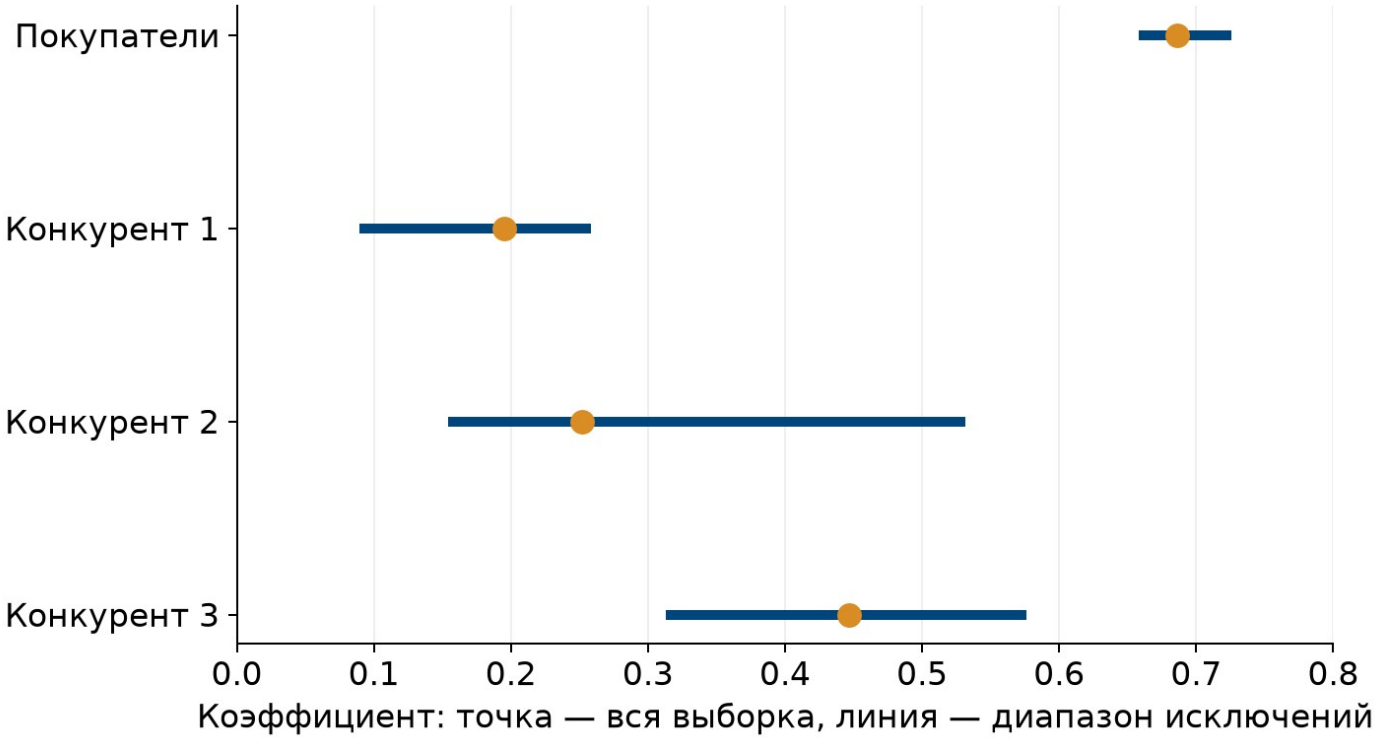
F(3, 51) = 4,10; p = 0,011

Отдельный конкурент
после 9 проверок с Холмом
не выделяется.

Покупатели +10% →
оценка суммы продаж +6,8%*
Вес: p Холма = 0,049 — на границе.

ln — натуральный логарифм; остальные факторы в исходной шкале. Результаты основной М3.
* Геометрическое среднее при прочих равных. Чувствительность к времени — следующий слайд.

5. Проверена устойчивость к товарам и времени



Добавлены 19 месяцев

Конкуренты совместно:
М3: p = 0,011
С месяцами: p = 0,061

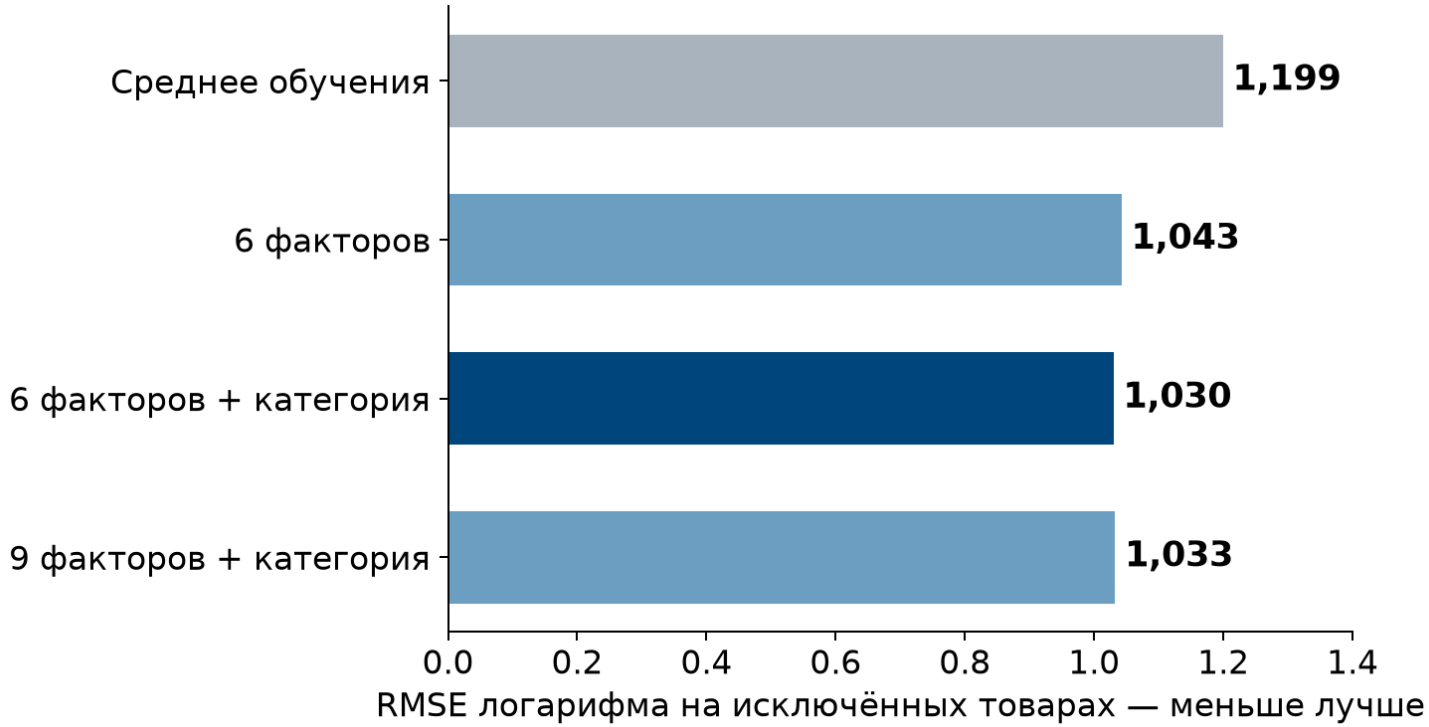
Вес: p после Холма
0,049 → 0,116

При учёте времени вывод на уровне 5% не сохраняется.

Слева — диапазоны оценок при 52 исключениях товара, не доверительные интервалы.
Справа — та же выборка с календарными эффектами; это не доказательство отсутствия связи.

6. Качество проверено на товарах вне обучения

5 частей по товарам: ни одна строка проверяемого товара не участвует в обучении.



С чем сравнивали

Простой прогноз среднего и три регрессии — на одних и тех же исключённых товарах.

Модель с категориями имеет RMSE 1,030. Расширенная — 1,033: выигрыша не получено.

Рост подгонки не перешёл в улучшение предсказания на выбранном разбиении.
Ошибки на шкале логарифма. Проверка не относится к будущим месяцам.

Итоги: что сделано и что удалось установить

Подготовлена воспроизводимая модель розничных продаж

Проверены 30 столбцов; сохранены 676 строк.
Сравнены 6 факторов, добавление категории и расширение до 9 факторов.

Связь конкурентных цен чувствительна к учёту времени

Основная М3: p = 0,011; с 19 месяцами: p = 0,061.
Совместная значимость на уровне 5% не сохраняется в календарном расширении.

Дополнительные признаки не улучшили предсказание

С рейтингом, объёмом и доставкой RMSE 1,033 против 1,030 без них.
На выбранном разбиении расширение модели себя не оправдало.

Ограничения: 52 товара; возможны общие ошибки категории и месяца. Выводы — о связях.

Спасибо за внимание!