Казанский федеральный
УНИВЕРСИТЕТ

Анализ данных розничной торговли с помощью множественной регрессии

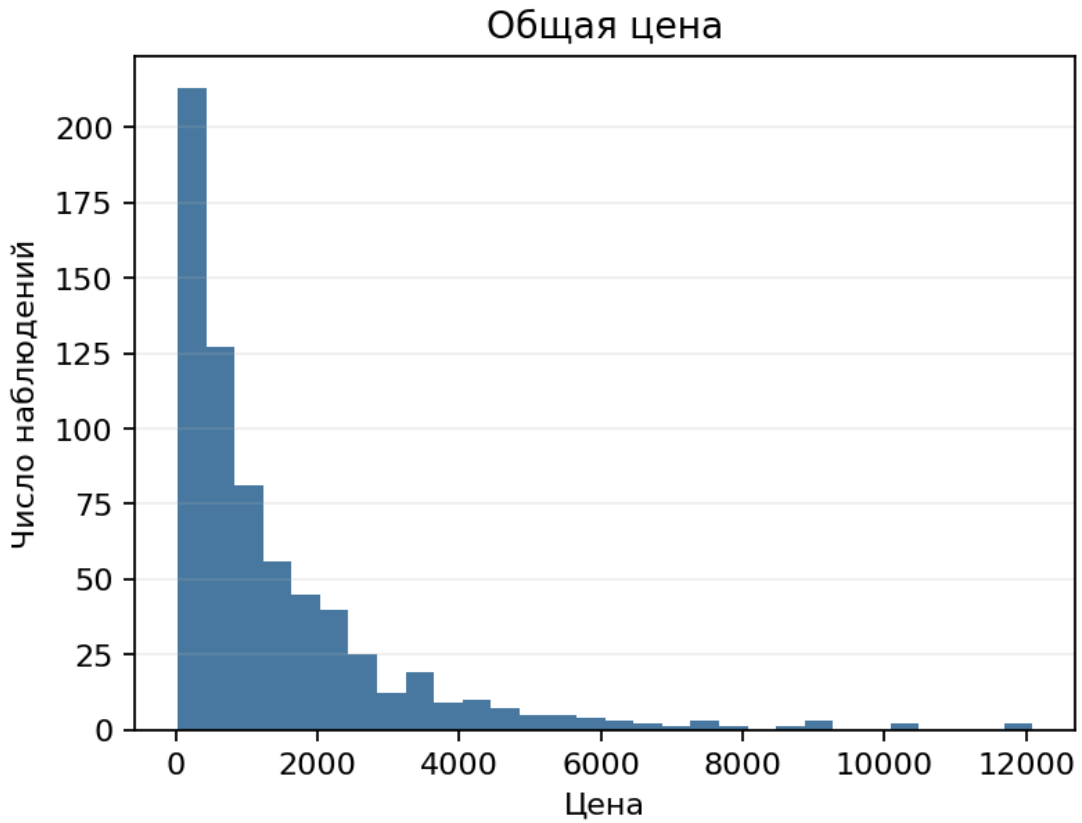
Связь общей цены с покупателями, весом и ценами трёх конкурентов

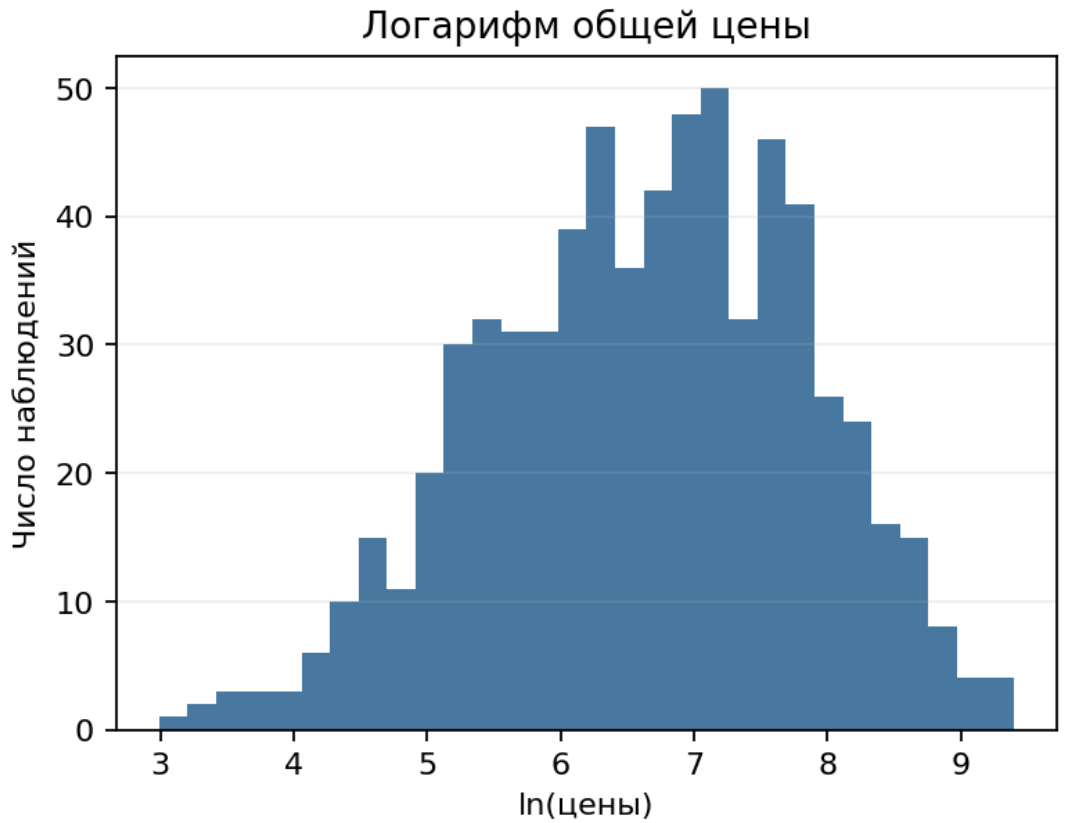
Максим Кибардин · группа 05-308 · Казань, 2026

Данные набора Retail Price

676 наблюдений по 52 товарам · январь 2017 — август 2018 · без пропусков и дублей

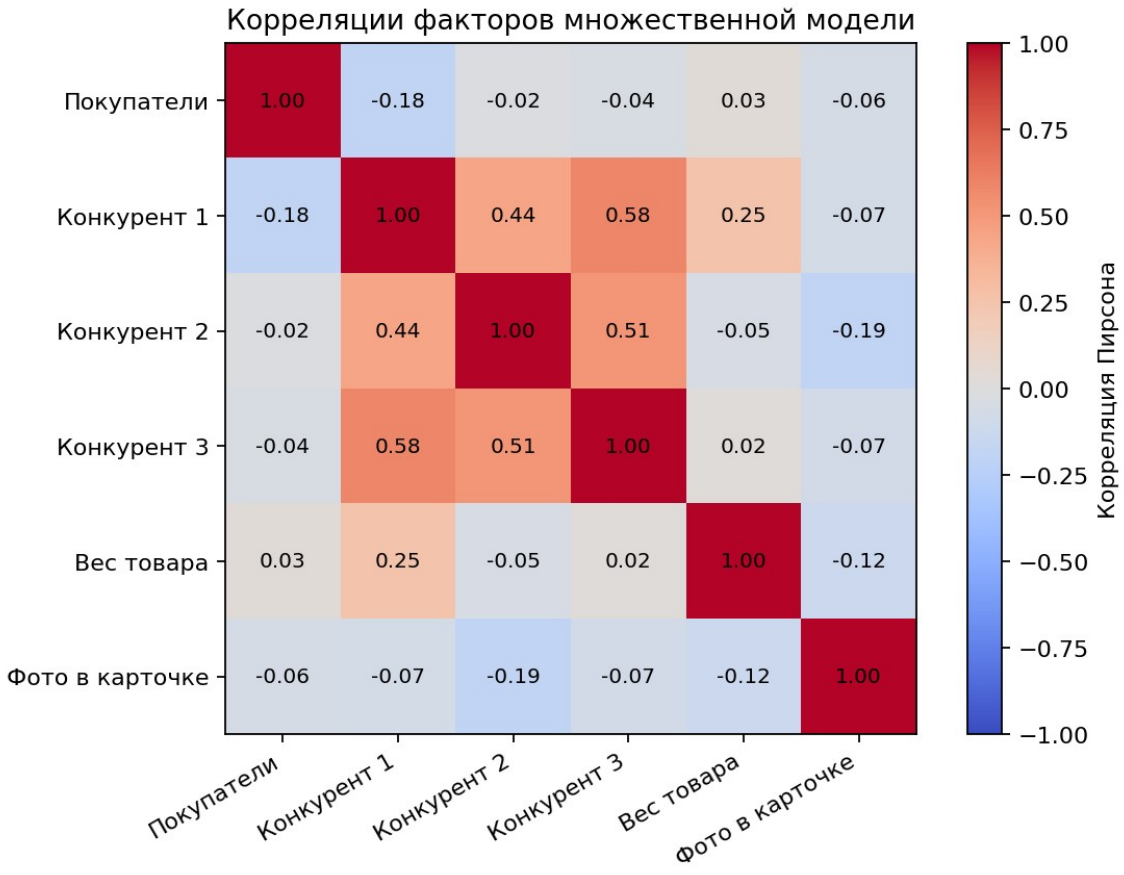
Средняя цена — 1 423; медиана — 808. Факторы: покупатели, 3 цены конкурентов, вес и число фото.





Логарифмирование сжимает длинный правый хвост общей цены.

Предварительная очистка и диагностика факторов



Тепловая карта: корреляции факторов множественной модели.

Почему выбраны эти факторы

Покупатели — спрос; цены трёх конкурентов — конкуренция; вес — свойство товара; фото — полнота карточки.

Проверка данных

0 пропусков, 0 полных дублей и 0 неположительных значений. Все 676 строк сохранены; крайние цены не удалялись автоматически.

Исключения и диагностика

unit_price × qty ≈ total_price; lag_price дублирует unit_price. s неясен; freight_price — доставка. score и volume не улучшили модель; 9 категорий требуют 8 индикаторов. VIF: 1,06–1,84.

Схема исследования

Три модели по отдельности

Покупатели + вес + фото карточки + цена одного конкурента.
В каждой модели меняется только конкурент.

Множественная модель

Покупатели + вес + фото карточки + цены всех трёх конкурентов.
Все факторы оцениваются одновременно.

Что сравниваю	Скорректированный R^2 трёх отдельных моделей на одной выборке.
Коэффициенты	p-value и 95%-ные доверительные интервалы; ошибки сгруппированы по товару.
Общий вклад	Кластерный F-тест проверяет совместную значимость трёх цен конкурентов.

Во всех моделях одинаковые 676 наблюдений; ошибки кластеризованы по 52 товарам.

Сравнение трёх отдельных моделей

Во всех моделях учтены покупатели, вес и число фотографий в карточке товара.

Конкурент	Коэффициент	p-value	95%-ный интервал	Скорр. R^2
comp_1	0,371	0,0121	[0,085; 0,656]	0,239
comp_2	0,724	$2{,}74 \cdot 10^{-6}$	[0,448; 0,999]	0,299
comp_3	0,539	0,00087	[0,233; 0,845]	0,258

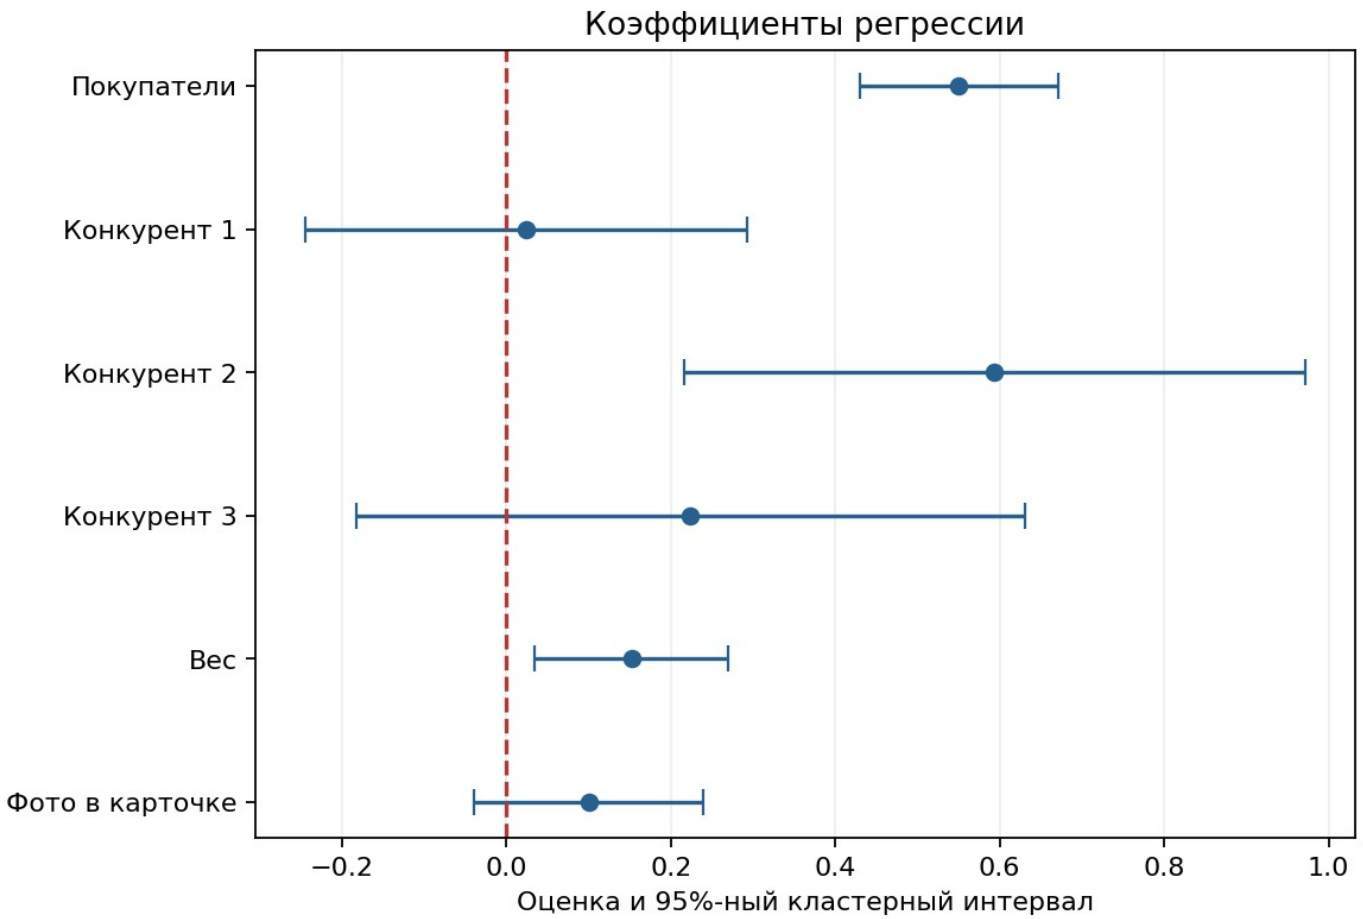
Во всех трёх моделях связь положительная и значима на уровне 5%.

Наибольший скорректированный R^2 — у модели с comp_2: 0,299.

Это лучшая подгонка в данной выборке, но не проверка прогноза на новых данных.

Множественная модель: все цены конкурентов вместе

Каждый коэффициент показывает условную связь при прочих равных.



Линии показывают кластерные 95%-ные доверительные интервалы.

Значимы по отдельности

Покупатели: β=0,550; p<0,001
comp_2: β=0,594; p=0,003
Вес: β=0,152; p=0,012

Не подтверждены отдельно

comp_1: p=0,856; comp_3: p=0,274;
фото карточки: p=0,154.
Интервалы включают ноль.

Совместные тесты

Конкуренты: $F(3, 51)=11,24$; $p<0,001$.
Модель: $F(6, 51)=23,98$; $p<0,001$.
$R^2=0,311$; скорр. $R^2=0,305$.

Интерпретация и ограничения



Разброс остатков неодинаков. Это визуальная диагностика, а не формальный тест.

Ограничения

- Данные наблюдательные: причинность не устанавливается.
- 52 товара и только период 2017–2018 годов.
- Не учтены сезонность, категории и другие факторы.
- Нет проверки модели на новых наблюдениях.

При росте на 10% модельная оценка цены меняется примерно на: покупатели +5,4%, comp_2 +5,8%, вес +1,5% (при прочих равных).

Спасибо за внимание!

Максим Кибардин
Студент группы 05-308