Министерство науки и высшего образования Российской Федерации

Федеральное государственное автономное образовательное учреждение
высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

Институт математики и механики им. Н.И. Лобачевского

Кафедра математической статистики

Курсовая работа

Анализ данных розничной торговли с помощью множественной регрессии

Студент группы 05-308
Кибардин Максим Олегович

«___»_____ 2026 г. _____ М.О. Кибардин

Научный руководитель
к.н., доцент
«___»_____ 2026 г. _____ Р.Ф. Салимов

Казань — 2026 г.

Оглавление

ВВЕДЕНИЕ 2

1. Линейная регрессия и статистическая проверка 4
   1.1 Идея модели и метода наименьших квадратов 4
   1.2 Логарифмические коэффициенты и качество модели 4
   1.3 Проверка коэффициентов и модели: t- и F-критерии 5

2. Анализ данных розничной торговли с помощью множественной регрессии 8
   2.1 Данные и выбор признаков 8
   2.2 Спецификация модели 11
   2.3 Результаты 12
   2.4 Краткая проверка модели и ограничения 13

ЗАКЛЮЧЕНИЕ 15

ЛИТЕРАТУРА 16

Введение

Цена товара зависит от его характеристик и положения на рынке. Статистическая модель позволяет кратко описать, как цена связана с выбранными характеристиками, и оценить точность таких выводов [1, 2]. В этой работе рассматривается задача анализа данных о розничной торговле.

Цель работы — провести обоснованную предварительную подготовку данных розничной торговли и с помощью множественной линейной регрессии оценить связи общей цены товара с покупательским спросом, конкурентными ценами и характеристиками товара.

Для достижения цели решаются следующие задачи:

1. кратко описать метод наименьших квадратов и способы проверки коэффициентов;
2. проверить качество данных, обосновать выбор признаков и оценить корреляции и VIF;
3. сравнить три модели, в каждой из которых используется цена одного конкурента;
4. оценить множественную модель с тремя ценами конкурентов, числом покупателей, весом и количеством фотографий в карточке;
5. интерпретировать коэффициенты, p-value, доверительные интервалы и качество модели;
6. проверить отдельные коэффициенты, совместный вклад цен конкурентов и значимость модели в целом;
7. указать ограничения анализа.

Объект исследования — наблюдения за товарами и их ценами в розничной торговле. Предмет исследования — статистические связи общей цены товара с покупательским спросом, конкурентными ценами, весом и характеристиками карточки товара.

Используется датасет Retail Price: 676 наблюдений по 52 товарам за 2017–2018 годы. Сравниваются три отдельные спецификации, затем оценивается модель со всеми тремя ценами конкурентов. Коэффициенты оцениваются методом наименьших квадратов; стандартные ошибки группируются по товару, поскольку одни и те же товары встречаются в выборке несколько раз.

1. Линейная регрессия и статистическая проверка

1.1 Идея модели и метода наименьших квадратов

Регрессионная модель описывает отклик y через несколько признаков x_j и случайную ошибку [1, 2]:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i. \tag{1.1}$$

Коэффициенты β_j показывают, как в среднем меняется отклик при изменении соответствующего признака, если остальные признаки модели фиксированы.

Метод наименьших квадратов (МНК) выбирает коэффициенты, при которых сумма квадратов остатков минимальна:

$$\widehat{\beta} = \arg\min_{\beta} \sum_{i=1}^{n} (y_i - \widehat{y}_i)^2. \tag{1.2}$$

В матричной записи при полном ранге матрицы признаков X решение имеет вид

$$\widehat{\beta} = (X^\top X)^{-1} X^\top y. \tag{1.3}$$

МНК используется во всех сравниваемых спецификациях; различаются только включённые цены конкурентов.

1.2 Логарифмические коэффициенты и качество модели

В используемой модели логарифмируются общая цена и пять непрерывных факторов: число покупателей, цены трёх конкурентов и вес товара. Количество фотографий включено в исходном масштабе. Поэтому коэффициенты при логарифмах можно приближённо интерпретировать как процентное изменение цены при увеличении соответствующего фактора на один процент, если остальные признаки модели не меняются; коэффициент числа

фотографий относится к добавлению одной фотографии. Например, коэффициент **0,5** соответствует связи роста признака на 1% с ростом цены примерно на 0,5%.

Качество подгонки кратко характеризуется коэффициентом детерминации:

$$R^2 = 1 - \frac{\sum_i (y_i - \widehat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}. \tag{1.4}$$

Он показывает, какая доля разброса отклика в данной выборке описывается моделью. Высокое значение R^2 само по себе не доказывает правильность модели или причинную связь.

1.3 Проверка коэффициентов и модели: t- и F-критерии

Для каждого коэффициента проверяется гипотеза

$$H_0 : \beta_j = 0, \qquad H_1 : \beta_j \neq 0. \tag{1.5}$$

Нулевая гипотеза означает, что в рамках выбранной модели данные не подтверждают связь отклика с этим признаком. Статистика критерия равна

$$t_j = \frac{\widehat{\beta}_j}{\mathrm{SE}_{\mathrm{cluster}}(\widehat{\beta}_j)}. \tag{1.6}$$

Стандартная ошибка с группировкой по товару учитывает, что несколько строк, относящихся к одному товару, могут быть похожи [2]. В расчётах 52 группы, поэтому для двусторонней проверки используется t-распределение с 51 степенью свободы.

Уровень значимости заранее выбран равным $\alpha = 0{,}05$. p-value показывает, насколько необычной была бы полученная статистика при условии, что нулевая гипотеза верна. Если p-value меньше 0,05, нулевая гипотеза отвергается.

Для двусторонней проверки p-value вычисляется через функцию распределения Стьюдента:

$$p_j = 2\left(1 - F_{t_{51}}\left(|t_j|\right)\right), \tag{1.7}$$

где $F_{t_{51}}$ — функция распределения t-распределения с 51 степенью свободы. В ноутбуке эта величина берётся из результата `statsmodels` после вызова `get_robustcov_results` с параметрами `cov_type='cluster'`, `use_t=True` и группировкой по `product_id`.

95%-ный доверительный интервал для коэффициента имеет вид

$$\widehat{\beta}_j \pm t_{0{,}975;51}\,\mathrm{SE}_{\mathrm{cluster}}(\widehat{\beta}_j). \tag{1.8}$$

Если интервал не содержит ноль, это согласуется с двусторонним тестом на уровне 5%. Интервал показывает диапазон значений коэффициента, совместимых с данными и выбранной моделью.

Скорректированный коэффициент детерминации рассчитывается по формуле

$$R^2_{\mathrm{adj}} = 1 - (1 - R^2)\frac{n-1}{n-k-1}, \tag{1.9}$$

где $n = 676$ — число наблюдений, а $k = 6$ — число регрессоров без константы. В ноутбуке значения R^2 и R^2_{adj} берутся из объекта `statsmodels` как `rsquared` и `rsquared_adj`.

Совместная гипотеза о нескольких коэффициентах проверяется кластерно-устойчивым F-критерием. Для ограничения $R\beta = r$ используется статистика Вальда

$$F = \frac{1}{q}(R\widehat{\beta} - r)^{\top}\left[R\widehat{\mathrm{Var}}(\widehat{\beta})R^{\top}\right]^{-1}(R\widehat{\beta} - r), \tag{1.10}$$

где q — число ограничений. Для трёх цен конкурентов $q = 3$, а для всей модели $q = 6$. В ноутбуке ограничения передаются в метод `f_test` кластерно-устойчивого результата `statsmodels`.

В расширенной модели отдельно проверяется гипотеза о нулевых коэффициентах всех шести факторов и гипотеза о совместном вкладе цен конкурентов. Для первой проверки нулевая гипотеза имеет вид

$$H_0 : \beta_1 = \gamma_1 = \gamma_2 = \gamma_3 = \beta_2 = \delta = 0, \tag{1.11}$$

то есть ни один из шести факторов не связан с откликом в рамках модели. Для второй проверки рассматривается ограничение $H_0 : \gamma_1 = \gamma_2 = \gamma_3 = 0$. Для обеих проверок используется F-тест на основе кластерной ковариационной матрицы; число степеней свободы равно соответственно $(6, 51)$ и

(3,51). Если p-value меньше 0,05, соответствующая нулевая гипотеза отвергается. Совместные тесты дополняют, но не заменяют проверку отдельных коэффициентов.

2. Анализ данных розничной торговли с помощью множественной регрессии

2.1 Данные и выбор признаков

В используемом файле данных Retail Price [3] содержатся 676 строк, 30 столбцов и 52 товара, наблюдаемых в разные месяцы 2017–2018 годов. В исходной таблице нет пропусков, полных дубликатов и повторов пары «товар–месяц». Для переменных итоговой модели нет нулевых или отрицательных значений, поэтому после проверок все 676 наблюдений сохранены. Автоматического удаления крайних значений не проводилось: без подтверждения ошибки ввода они могут быть реальными наблюдениями.

Набор факторов выбран по вопросу исследования и содержательной роли переменных: число покупателей служит показателем спроса, цены всех трёх конкурентов описывают конкурентную среду, вес отражает физическую характеристику товара, а число фотографий включено как контроль полноты карточки. Последний признак не выбран по статистической значимости: его коэффициент в итоговой модели незначим. В 95% строк относительное расхождение между `total_price` и произведением `unit_price` на `qty` не превышает 0,283%; поэтому эти два показателя не включаются как регрессоры, чтобы не описывать целевую переменную почти через её собственные составляющие. Корреляция `unit_price` и `lag_price` равна 0,994; близкие ценовые показатели не включаются одновременно. Признак `s` исключён, поскольку его смысл в описании неоднозначен.

В модель включено число фотографий `product_photos_qty` как контрольная характеристика карточки (от 1 до 8). `freight_price` отражает отдельную стоимость доставки, не включённую в `total_price`; в ней есть одно нулевое значение, поэтому логарифмировать её без дополнительного преобразования нельзя. Девять категорий товара потребовали бы восьми индикаторных признаков. Проверка `product_score` и `volume` по отдельности не повысила скорректированный R^2 (p-value 0,938 и 0,712), поэтому эти признаки оставлены за рамками компактной спецификации. Календар-

ные переменные потребовали бы отдельной модели временных эффектов. Крайние значения не удаляются только по статистическому порогу.

Для шести регрессоров рассчитаны парные корреляции и факторы инфляции дисперсии (VIF). Максимальная абсолютная парная корреляция равна 0,582. Значения VIF находятся в диапазоне 1,055–1,839: это ниже часто используемого ориентировочного порога 5, поэтому оснований удалять включённые факторы по причине выраженной мультиколлинеарности нет. Число фотографий сохраняется как контроль по содержательному основанию, хотя его индивидуальный коэффициент незначим ($p = 0{,}154$). Порог VIF является диагностической эвристикой, а не строгим критерием.

Для отдельного регрессора VIF определяется через вспомогательную регрессию этого регрессора на остальные факторы:

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}. \tag{2.1}$$

Здесь R_j^2 — коэффициент детерминации вспомогательной регрессии. В ноутбуке VIF вычисляется функцией `variance_inflation_factor` из `statsmodels`; матрица корреляций строится методом `DataFrame.corr()`.

Краткие характеристики переменных приведены в Таблице 2.1. Средняя общая цена заметно выше медианной, что указывает на возможную правостороннюю асимметрию. Логарифмическая форма также упрощает интерпретацию коэффициентов как эластичностей.

На Рисунке 2.1 показано распределение общей цены до и после логарифмирования. На исходной шкале заметен правый хвост, а логарифмирование сжимает большие значения. График помогает описать распределение и выбранное преобразование, но сам по себе не доказывает корректность модели.

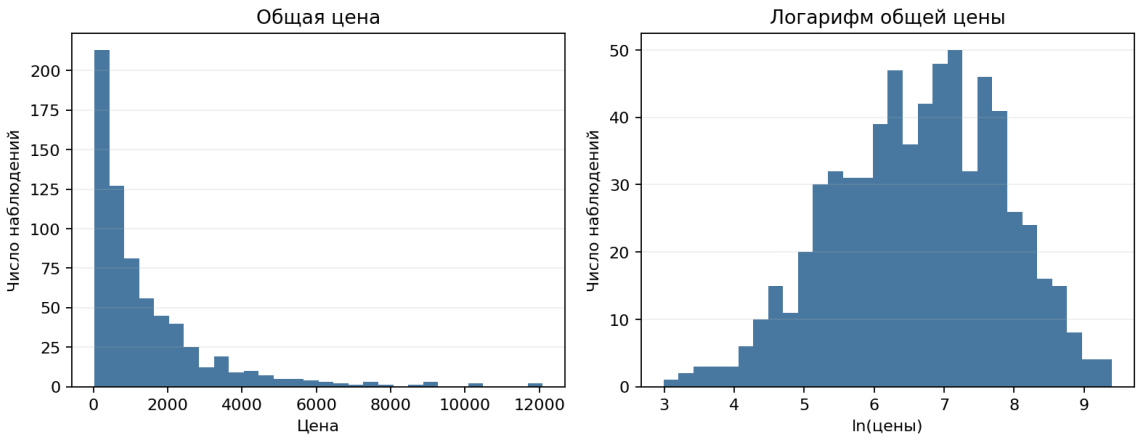


Рис. 2.1: Распределение общей цены и её натурального логарифма

Таблица 2.1: Описательная статистика исходных переменных

Переменная	Среднее	Медиана	Минимум	Максимум
Общая цена	1422,71	807,89	19,90	12095,00
Число покупателей	81,03	62,00	1,00	339,00
Цена конкурента 1	79,45	69,90	19,90	349,90
Цена конкурента 2	92,93	89,99	19,90	349,90
Цена конкурента 3	84,18	59,90	19,90	255,61
Вес товара, г	1847,50	950,00	100,00	9750,00
Число фотографий	1,99	1,50	1,00	8,00

Для краткой оценки взаимосвязи рассчитаны парные корреляции Пирсона между логарифмированными ценами конкурентов (Таблица 2.2). Корреляции умеренные; при совместном включении этих переменных важно отличать их отдельные связи от совместного результата. Попарная корреляция показывает только связи двух признаков; поэтому её дополняет расчёт VIF для всех шести регрессоров.

Таблица 2.2: Парные корреляции логарифмированных цен конкурентов

Признак	Цена конкурента 1	Цена конкурента 2	Цена конкурента 3
Цена конкурента 1	1,0000	0,4358	0,5815
Цена конкурента 2	0,4358	1,0000	0,5117
Цена конкурента 3	0,5815	0,5117	1,0000

В Таблице 2.3 приведены VIF всех регрессоров итоговой модели. Все значения заметно ниже ориентировочного уровня 5; поэтому выбранные факторы сохранены.

Таблица 2.3: Факторы инфляции дисперсии регрессоров модели

Фактор	VIF
Число покупателей	1,055
Цена конкурента 1	1,839
Цена конкурента 2	1,495
Цена конкурента 3	1,755
Вес товара	1,152
Число фотографий	1,063

2.2 Спецификация модели

Чтобы сравнить цены конкурентов при одинаковых контрольных признаках, сначала оцениваются три отдельные модели. Для каждой цены конкурента $j = 1, 2, 3$ используется спецификация

$$\begin{aligned} \ln(\texttt{total_price}_i) = \beta_0 &+ \beta_1 \ln(\texttt{customers}_i) \\ &+ \gamma_j \ln(\texttt{comp_j}_i) + \beta_2 \ln(\texttt{product_weight_g}_i) \\ &+ \delta\, \texttt{product_photos_qty}_i + \varepsilon_i. \end{aligned} \tag{2.2}$$

Затем оценивается расширенная модель, в которой все три цены учитываются одновременно:

$$\begin{aligned} \ln(\texttt{total_price}_i) = \beta_0 &+ \beta_1 \ln(\texttt{customers}_i) \\ &+ \gamma_1 \ln(\texttt{comp_1}_i) + \gamma_2 \ln(\texttt{comp_2}_i) \\ &+ \gamma_3 \ln(\texttt{comp_3}_i) + \beta_2 \ln(\texttt{product_weight_g}_i) \\ &+ \delta\, \texttt{product_photos_qty}_i + \varepsilon_i. \end{aligned} \tag{2.3}$$

Коэффициенты при пяти логарифмированных признаках приблизительно интерпретируются как эластичности; коэффициент δ показывает связь с добавлением одной фотографии. Во всех спецификациях используются одни и те же 676 наблюдений. Стандартные ошибки кластеризуются по 52 товарам. Скорректированный R^2 сравнивает подгонку трёх отдельных моделей в этой выборке; он не является оценкой точности прогноза на новых данных.

2.3 Результаты

В Таблице 2.4 приведены три модели с ценой одного конкурента; во всех также учтены покупатели, вес и число фотографий. Все три оценки положительны и значимы при 5%. Наибольший скорректированный R^2 у спецификации с ценой второго конкурента; это лучшая подгонка в данной выборке, но не проверка прогноза на новых данных.

Таблица 2.4: Сравнение отдельных моделей с разными ценами конкурентов

Конкурент	$\widehat{\gamma}_j$	p-value	95%-ный кластерный интервал	Скорр. R^2
Первый	0,371	0,0121	[0,085; 0,656]	0,239
Второй	0,724	$2{,}74 \cdot 10^{-6}$	[0,448; 0,999]	0,299
Третий	0,539	$8{,}70 \cdot 10^{-4}$	[0,233; 0,845]	0,258

Далее рассматривается множественная модель (2.3), где каждая оценка конкурента отражает условную связь при фиксации двух других цен, покупателей, веса и числа фотографий. В Таблице 2.5 представлены двусторонние t-проверки, p-value и 95%-ные кластерные доверительные интервалы.

Таблица 2.5: Результаты расширенной модели со всеми ценами конкурентов

Признак	Коэффициент	SE	t	p-value	95%-ный интервал
Число покупателей	0,550	0,060	9,16	$2{,}39 \cdot 10^{-12}$	[0,430; 0,671]
Цена конкурента 1	0,024	0,134	0,18	0,856	[−0,244; 0,293]
Цена конкурента 2	0,594	0,188	3,16	0,0027	[0,216; 0,971]
Цена конкурента 3	0,224	0,202	1,11	0,274	[−0,183; 0,630]
Вес товара	0,152	0,059	2,59	0,0124	[0,034; 0,270]
Число фотографий	0,100	0,069	1,45	0,154	[−0,039; 0,240]

В множественной модели после одновременного учёта трёх цен конкурентов индивидуальная положительная связь сохраняется для цены второго конкурента ($p = 0{,}0027$). Для первого и третьего конкурентов доверительные интервалы включают ноль. Число фотографий также незначимо отдельно ($p = 0{,}154$); включение его как контрольного признака не является утверждением о подтверждённом эффекте.

Совместный кластерно-устойчивый тест коэффициентов трёх цен конкурентов даёт $F(3, 51) = 11{,}24$ и $p = 8{,}98 \cdot 10^{-6}$. Цены конкурентов значимы совместно. Тест всех шести коэффициентов также значим: $F(6, 51) = 23{,}98$, $p = 2{,}91 \cdot 10^{-13}$.

Коэффициент детерминации множественной модели равен $R^2 = 0{,}311$, скорректированный $R^2 = 0{,}305$. Модель описывает около 31,1% разброса логарифма цены в этой выборке.

Для наглядной интерпретации при росте признака на 10% модельная процентная оценка рассчитывается как $((1{,}10)^{\widehat{\beta}} - 1) \cdot 100\%$. При прочих равных она составляет около 5,4% для числа покупателей, 5,8% для цены второго конкурента и 1,5% для веса. Число фотографий интерпретируется на одну фотографию; его коэффициент незначим, поэтому точечную оценку не следует представлять как подтверждённую связь. Интервалы для `comp_1` и `comp_3` также включают ноль.

На Рисунке 2.2 оценки шести факторов показаны с 95%-ными кластерными доверительными интервалами; вертикальная линия соответствует нулю.

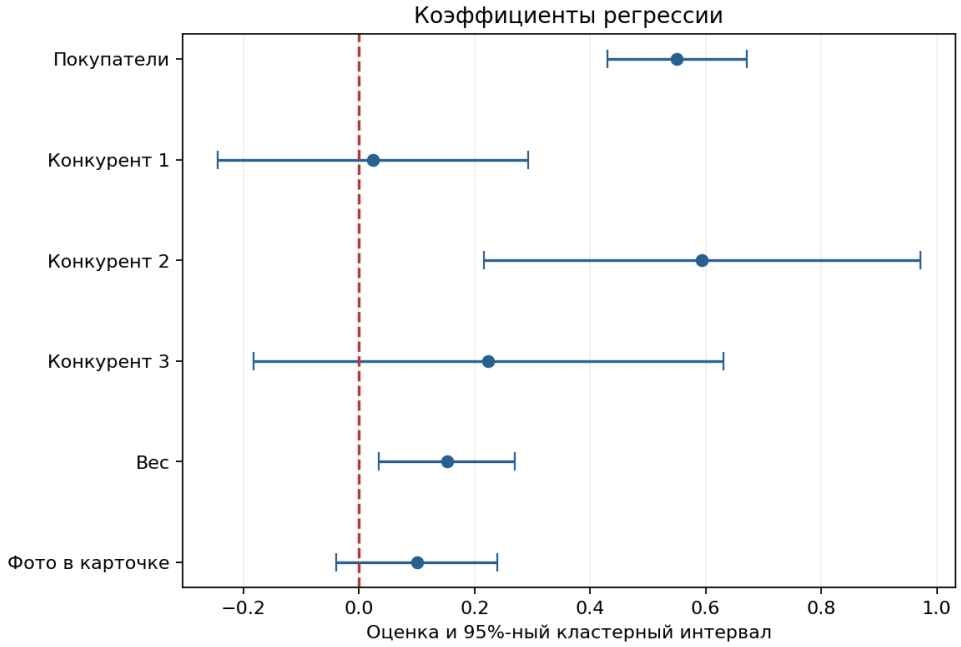


Рис. 2.2: Оценки коэффициентов и 95%-ные кластерные доверительные интервалы

2.4 Краткая проверка модели и ограничения

На Рисунке 2.3 показаны остатки модели в зависимости от предсказанных значений. Точки расположены по обе стороны от нулевой линии, однако разброс остатков неодинаков и присутствуют отдельные большие отклоне-

ния. График служит краткой визуальной проверкой и не заменяет формальные диагностические тесты.



Рис. 2.3: Остатки модели и предсказанные значения логарифма цены

У исследования есть несколько ограничений. Во-первых, наблюдательные данные позволяют говорить о связи, но не о причинном влиянии. Во-вторых, модель включает шесть факторов, но не учитывает категории товаров, сезонность и другие возможные характеристики. В-третьих, сравнение спецификаций выполнено на той же выборке и не является проверкой точности прогноза на новых товарах. Кластерные стандартные ошибки учитывают повторные наблюдения по одному товару при оценке неопределённости, но не устраняют возможное влияние неучтённых характеристик товаров.

Заключение

В работе проверено качество данных: пропусков, полных дубликатов и повторов «товар–месяц» нет, все 676 наблюдений сохранены. Обоснован выбор шести регрессоров и объяснено исключение других столбцов. Сравнивались три модели с ценой одного конкурента и числом фотографий, затем оценивалась множественная модель со всеми ценами конкурентов. Стандартные ошибки сгруппированы по товару; приведены t-проверки, p-value и 95%-ные интервалы.

В отдельных моделях все цены конкурентов положительны и значимы; наибольший скорректированный R^2 у `comp_2`. В множественной модели индивидуально значима цена второго конкурента, а все три конкурентные цены значимы совместно. Также значимы число покупателей и вес. Число фотографий включено как контроль, но его отдельная связь не подтверждена. $R^2 = 0{,}311$, скорректированный $R^2 = 0{,}305$.

Совместный тест шести коэффициентов ($F(6,51) = 23{,}98,\ p < 0{,}001$) и тест трёх цен конкурентов ($F(3,51) = 11{,}24,\ p < 0{,}001$) подтверждают значимость соответствующих групп факторов, но не каждого конкурента по отдельности.

Итак, в этой выборке цена второго конкурента показывает наиболее ясную индивидуальную связь с общей ценой после учёта других факторов. Результаты остаются статистическими связями, а не доказательством причинного влияния; для более широких выводов нужны дополнительные данные и проверка на новых наблюдениях.

Литература

1. Кобзарь А.И. Прикладная математическая статистика. — М.: Физматлит, 2006.

2. Wooldridge J.M. Introductory Econometrics: A Modern Approach. — 6th ed. — Cengage Learning, 2016.

3. Retail Price Optimization. Набор данных. Kaggle. URL: `https://www.kaggle.com/datasets/suddharshan/retail-price-optimization` (дата обращения: 22.10.2026).