Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования «КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

ИНСТИТУТ МАТЕМАТИКИ И МЕХАНИКИ ИМ. Н.И. ЛОБАЧЕВСКОГО
КАФЕДРА МАТЕМАТИЧЕСКОЙ СТАТИСТИКИ

Направление подготовки (специальность): 02.03.01 – Математика и компьютерные науки
Профиль (специализация): Наука о данных

КУРСОВАЯ РАБОТА

АНАЛИЗ ДАННЫХ РОЗНИЧНОЙ ТОРГОВЛИ С ПОМОЩЬЮ МНОЖЕСТВЕННОЙ РЕГРЕССИИ

Студент 3 курса
группы 05-308 Кибардин М. О.
«____» _____ 2026 г.

Научный руководитель
канд. физ.-мат. наук Салимов Р. Ф.
«____» _____ 2026 г.

Казань – *2026*

СОДЕРЖАНИЕ

Введение 3
1 Предварительный анализ данных 5
1.1 Источник данных и смысл переменных 5
1.2 Предварительная обработка и выбор признаков 6
1.3 Описательная статистика и распределения 8
1.4 Предварительный анализ связей 9
1.5 Исследовательские гипотезы 12
2 Множественная регрессия и оценка результатов 13
2.1 Построение и сравнение спецификаций 13
2.2 Проверка коэффициентов и совместных гипотез 15
2.3 Диагностика и устойчивость модели 19
2.4 Интерпретация результатов 23
2.5 Оценка качества предсказания 25
Заключение 28
Список использованных источников 30
Приложение А. Подготовка данных и предварительный анализ . . . 31
Приложение Б. Модели и проверка гипотез 34
Приложение В. Диагностика и интерпретация 36
Приложение Г. Качество предсказания и воспроизводимость 37
Приложение Д. Дополнительные оценки 39

ВВЕДЕНИЕ

Месячная сумма продаж зависит и от цены товара, и от количества проданных единиц. Поэтому прежде чем строить регрессию, нужно определить, какой из этих показателей требуется объяснить. В этой работе рассматривается сумма продаж товара за месяц. По данным Retail Price Optimization исследуется, как она связана с покупательской активностью, ценами конкурентов и свойствами товара.

Для сравнения товаров используются несколько объясняющих переменных одновременно [1, 2]. Например, более высокая цена конкурента может встречаться у товаров из более дорогой категории. Парная корреляция в таком случае смешивает ценовую связь с различиями ассортимента. Множественная регрессия позволяет включить категорию в уравнение и проследить, как после этого изменятся оценки конкурентных цен.

Цель работы — оценить связь месячной суммы продаж с покупательской активностью, ценами трёх конкурентов и характеристиками товара с помощью множественной регрессии, проверить устойчивость полученных оценок и сравнить качество предсказаний для товаров, не участвовавших в обучении.

Объект исследования — товары розничной торговли, представленные в данных за январь 2017 — август 2018 года. **Предмет исследования** — связь их месячных сумм продаж с выбранными признаками. Особое внимание уделяется конкурентным ценам: проверяется, сохраняется ли их совместная связь с продажами после включения категории и остальных характеристик.

Задачи работы:

1. определить единицу наблюдения, уточнить смысл столбцов и проверить таблицу на ошибки;

2. описать распределение продаж, сравнить категории и рассчитать парные связи признаков;

3. оценить регрессионные модели с разным составом факторов;

4. рассчитать интервалы коэффициентов и проверить отдельные факторы и их блоки с учётом повторных наблюдений;

5. исследовать остатки и изменение оценок при исключении товара и добавлении календарных месяцев;

6. объяснить полученные коэффициенты и сравнить ошибки предсказания на товарах вне обучения.

В таблице Retail Price Optimization [3] содержится 676 наблюдений по 52 товарам. Несколько месячных записей относятся к одному и тому же товару. Эта особенность учтена в расчётах: стандартные ошибки сгруппированы по товару, а в предсказательной проверке все его записи исключаются из обучения вместе. Полная модель включает девять числовых факторов и восемь индикаторов категории; вместе с константой оценивается 18 коэффициентов.

Набор ранее изучался в более простой модели, поэтому дальнейшие проверки имеют поисковый характер. Их задача — сопоставить спецификации и установить, какие выводы зависят от выбора факторов. Коэффициенты описывают статистические связи. Для вывода о причинном влиянии или назначения оптимальной цены имеющихся данных недостаточно; прогноз будущих месяцев также требует отдельного исследования.

Расчёты выполнены на Python с использованием NumPy, pandas, SciPy, statsmodels и scikit-learn [4–8]. Первая глава посвящена данным и предварительному анализу, вторая — построению и проверке моделей. Основной код приведён в приложениях после списка литературы; исполняемый ноутбук сохраняет таблицы и графики.

1 Предварительный анализ данных

1.1 Источник данных и смысл переменных

Источник данных — набор Retail Price Optimization, размещённый на Kaggle [3]. Для расчётов используется CSV с 30 столбцами. В доступном описании не указаны валюта и подробный способ получения ряда агрегатов. Поэтому денежные величины далее сохраняют единицы исходной таблицы, а смысл спорных полей уточняется по их значениям и связям с другими столбцами.

Одна строка относится к товару `product_id` в месяце `month_year`. После преобразования дат из формата день–месяц–год получено 20 различных месяцев. Набор образует несбалансированную панель: товары наблюдаются на протяжении неодинакового числа месяцев. Распределение по девяти категориям приведено в таблице 1.1.

Таблица 1.1 — Состав выборки по товарным категориям

Категория	Строк	Товаров
bed_bath_table	61	5
computers_accessories	69	6
consoles_games	22	2
cool_stuff	57	5
furniture_decor	48	4
garden_tools	160	10
health_beauty	130	10
perfumery	26	2
watches_gifts	103	8

Для определения смысла `total_price` его значения сопоставлены с произведением цены единицы `unit_price` и количества `qty`. Расхождение оценивалось по формуле

$$d_i = \frac{|T_i - U_i N_i|}{T_i}, \tag{1.1}$$

Здесь T_i — значение `total_price`, U_i — цена единицы `unit_price`, N_i — количество `qty`, i — номер строки. В 643 из 676 строк расхождение меньше 0,3% ($d_i < 0{,}003$); наибольшее составляет около 3,06%. На этом основании в работе T_i принято за сумму продаж товара за месяц. Для моделирования сохранён исходный столбец `total_price`: он не заменяется произведением

двух других полей. Доставка рассматривается как отдельный фактор и к отклику не прибавляется.

У поля `customers` обнаружена следующая особенность: во всех 154 сочетаниях «категория–месяц» товары одной категории имеют одинаковое значение этого показателя. Далее он используется как характеристика покупательской активности категории за месяц. Его точный способ расчёта неизвестен, поэтому считать эти значения числом покупателей отдельного товара было бы необоснованно.

Конкурентные цены представлены столбцами `comp_1`, `comp_2`, `comp_3`. Обозначения «первый», «второй» и «третий» соответствуют их номерам в CSV. Сведения о конкретных торговых организациях и правилах сопоставления товаров недоступны. В регрессии эти поля используются как ценовые показатели конкурентного окружения.

При проверке записей одного товара оказалось, что его вес, объём, рейтинг и число фотографий от месяца к месяцу не меняются. Связи этих четырёх признаков с продажами оцениваются по различиям между 52 товарами. Месячные записи дают сведения о продажах во времени, но не добавляют новых значений постоянных свойств товара.

1.2 Предварительная обработка и выбор признаков

Проверка охватывала пропуски, полные дубликаты, повторения пары «товар–месяц», конечность чисел и соответствие полей месяца и года дате. Отдельно проверены значения, к которым применяется логарифм. Ошибок по этим условиям не найдено: все семь логарифмируемых полей, включая отклик, положительны; отрицательной доставки нет, один ноль допустим. После обработки в таблице осталось 676 строк.

По итогам проверки удалять строки или заполнять пропуски не потребовалось. Обработка состояла в преобразовании даты, проверке ключа и подготовке модельных шкал. Крайние значения сохранены: сам по себе выход за границы межквартильного диапазона ещё не указывает на ошибку данных. Их влияние оценивается далее при поочерёдном исключении товаров.

В модель включены признаки, описывающие разные стороны продажи. Покупатели характеризуют активность категории, конкурентные цены

— ценовое окружение, вес и объём — физические свойства. Фотографии и рейтинг относятся к карточке и оценке товара, доставка — к условиям продажи. Категория введена, чтобы учитывать различия ассортимента при сопоставлении этих связей.

Таблица 1.2 — Роли переменных в исследовании

Группа	Решение и причина
`total_price`	Отклик; натуральный логарифм суммы продаж.
`customers`, `comp_1-3`	Логарифмы; покупательская активность и конкурентное окружение.
`product_weight_g`, `volume`	Логарифмы; физические свойства с проверкой взаимного дублирования.
`product_photos_qty`, `product_score`	Исходная шкала; число фотографий и рейтинг.
`freight_price`	Исходная шкала; нулевое значение допустимо.
`product_category_name`	Восемь индикаторов девяти категорий.
`unit_price`, `qty`	Исключены: почти арифметически восстанавливают отклик.
`lag_price`	Оставлен для отдельной задачи временного прогнозирования.
Длины названия и описания	Описаны, но не добавлены к выбранным характеристикам карточки.
`ps1-3`, `fp1-3`	Не включены: требуют уточнения сопоставления конкурентов и расширяют вопрос исследования.
Календарные поля, `s`	Календарь описывает период и используется в дополнительной проверке с индикаторами месяцев; в основную М3 не входит. Смысл `s` не подтверждён; столбец исключён.

Результаты проверки всех 30 полей сохранены отдельно: тип, число различных значений, пропуски, а для числовых столбцов также диапазон и число товаров с изменениями во времени. Этот аудит позволяет проследить выбор столбцов, в том числе оставшихся за пределами регрессии. Их исключение связано с постановкой задачи и доступным описанием, а не с доказанным отсутствием связи с продажами.

Рейтинг, объём и доставка добавлены единым блоком по плану расширения модели. Их вклад рассматривается совместно и по изменению ошибки вне обучения; прежние p-value не использовались для отбора. Базой категории служит `garden_tools`, где представлены 10 товаров. Если число товаров совпадает, применяется алфавитный порядок названий. Такое правило выбора базы не использует значения отклика.

1.3 Описательная статистика и распределения

Таблица 1.3 показывает характеристики переменных в исходном масштабе. Средняя сумма продаж равна 1422,71, медиана — 807,89; стандартное отклонение 1700,12. Большой разрыв среднего и медианы согласуется с правосторонней асимметрией. Наблюдаются значения от 19,90 до 12095,00.

Таблица 1.3 — Описательная статистика исходных переменных

Переменная	Среднее	Медиана	Ст. откл.	Мин.	Макс.
Сумма продаж	1422,709	807,890	1700,123	19,900	12095,000
Покупатели	81,028	62,000	62,056	1,000	339,000
Конкурент 1	79,452	69,900	47,933	19,900	349,900
Конкурент 2	92,930	89,990	49,481	19,900	349,900
Конкурент 3	84,183	59,900	47,746	19,900	255,610
Вес	1847,499	950,000	2274,808	100,000	9750,000
Объём	10664,627	8000,000	9172,802	640,000	32736,000
Фотографии	1,994	1,500	1,420	1,000	8,000
Рейтинг	4,086	4,100	0,232	3,300	4,500
Доставка	20,682	17,518	10,082	0,000	79,760

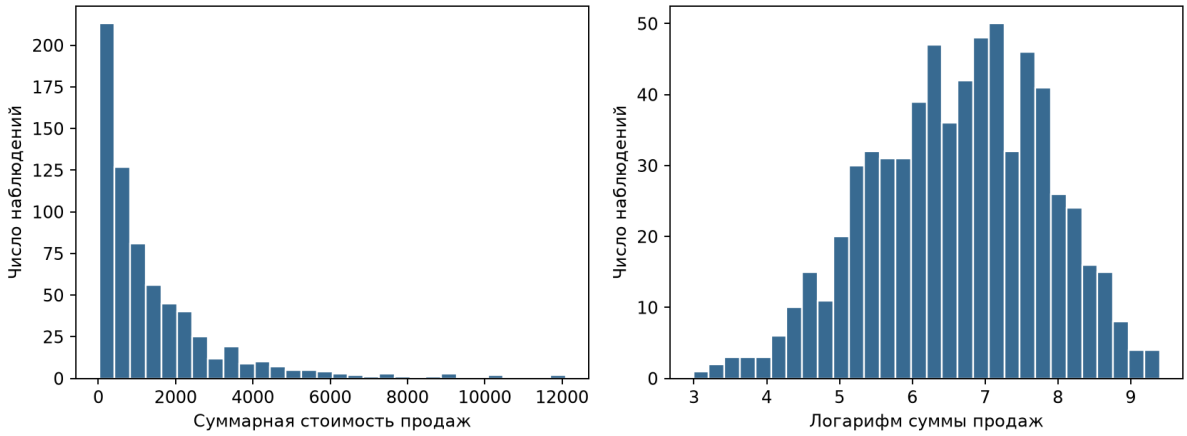


Рисунок 1.1 — Распределение суммы продаж и её натурального логарифма

Логарифмирование сжимает верхний хвост и позволяет описывать относительные связи. В модели логарифмируются сумма продаж, покупатели, три конкурентные цены, вес и объём. Фотографии, рейтинг и доставка остаются в исходном масштабе. Для доставки такой выбор сохраняет ноль без произвольного прибавления константы.

Рейтинг лежит в пределах от 3,3 до 4,5 при стандартном отклонении 0,232. При столь небольшом разбросе данных для оценки его связи с прода-

жами немного. Число фотографий принимает значения от 1 до 8. Медиана по месячным строкам равна 1,5: для чётного числа строк она получена усреднением двух центральных значений.

Логарифмы выбраны для работы с асимметричными величинами и относительными изменениями. Нормальное распределение самих факторов для МНК не требуется, поэтому тест Шапиро–Уилка для каждого столбца не применялся как предварительное условие построения модели. Пригодность формы уравнения далее оценивается по остаткам, одному дополнительному квадратичному члену и ошибкам вне обучения.

1.4 Предварительный анализ связей

Коэффициент корреляции Пирсона двух переменных определяется формулой

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}. \tag{1.2}$$

В расчёте участвуют n пар значений x_i, y_i; $\bar{x}, \bar{y}$ обозначают средние, а $\sum$ — суммирование по строкам. Корреляция Пирсона характеризует линейную связь и лежит от -1 до 1. Для корреляции Спирмена вместо значений берутся ранги; совпадающим значениям назначается средний ранг. Оба расчёта выполнены через `DataFrame.corr` с разными аргументами `method`.

Расчёт выполнен на шкалах будущей модели. Корреляции используются описательно: обычные p-value при предположении независимости 676 строк не вычисляются. При повторных наблюдениях такое предположение не обосновано.

Таблица 1.4 — Парные связи факторов с логарифмом суммы продаж

Фактор	Пирсон	Спирмен
Покупатели	0,432	0,410
Конкурент 1	0,133	0,165
Конкурент 2	0,276	0,261
Конкурент 3	0,214	0,198
Вес	0,146	0,128
Фотографии	0,017	-0,010
Рейтинг	0,002	-0,017
Объём	0,019	0,009
Доставка	0,078	0,174

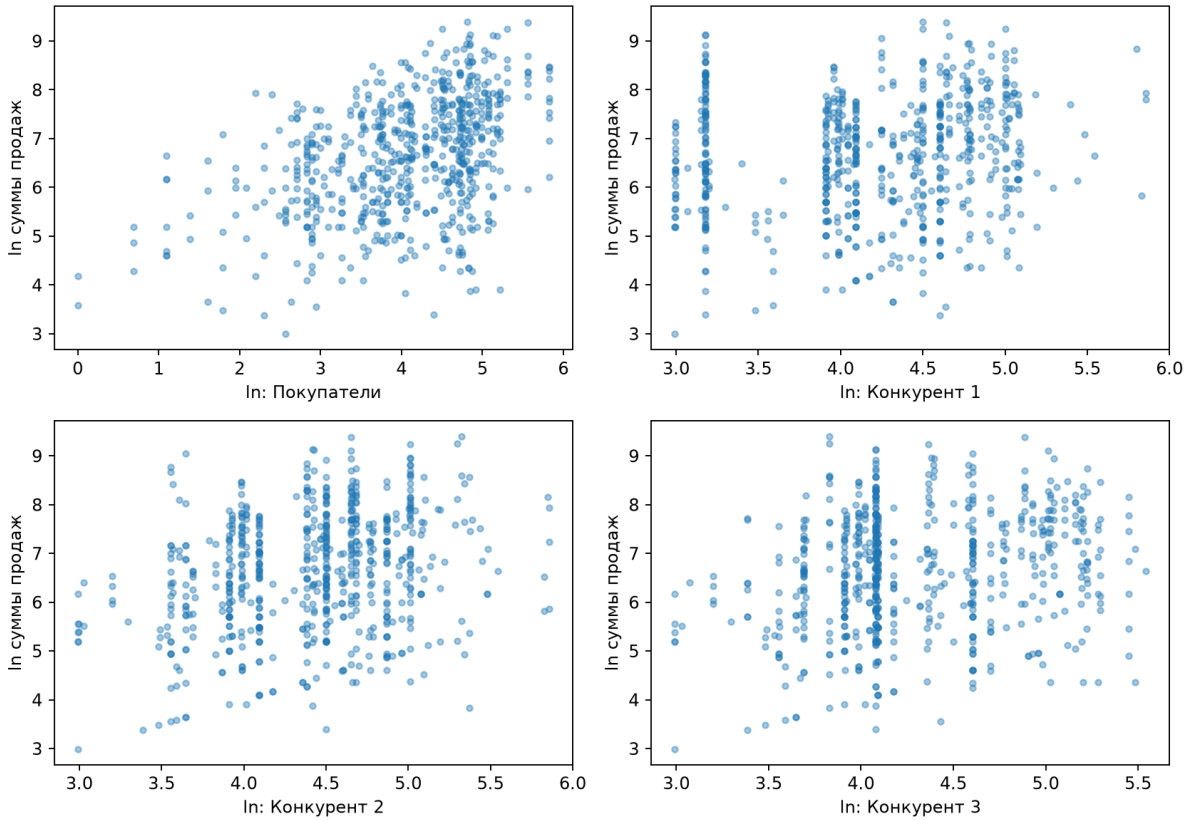


Рисунок 1.2 — Связи логарифма суммы продаж с покупателями и конкурентными ценами

Наиболее выраженная положительная парная связь с откликом наблюдается у числа покупателей: $r = 0{,}432$. Среди конкурентных цен наибольшая корреляция у второго столбца: $r = 0{,}276$. У рейтинга, фотографий и объёма парная корреляция близка к нулю. Однако такой результат не определяет коэффициент после учёта категории и других факторов: условная и парная связи отвечают на разные вопросы.

Диаграммы рассеяния показывают значительный разброс при одинаковых значениях факторов. Значит, ни один из них не даёт точного описания суммы продаж сам по себе. Распределения категорий перекрываются, но отличаются положением и разбросом. Категориальные индикаторы позволяют учитывать сдвиги среднего логарифма отклика без предположения об одинаковом уровне продаж всех категорий.

В категориях `consoles_games` и `perfumery` всего по два товара. Число месячных строк в таких категориях не устраняет недостаток независимых товаров. Отдельные категориальные интервалы и результаты проверки следует интерпретировать осторожно.

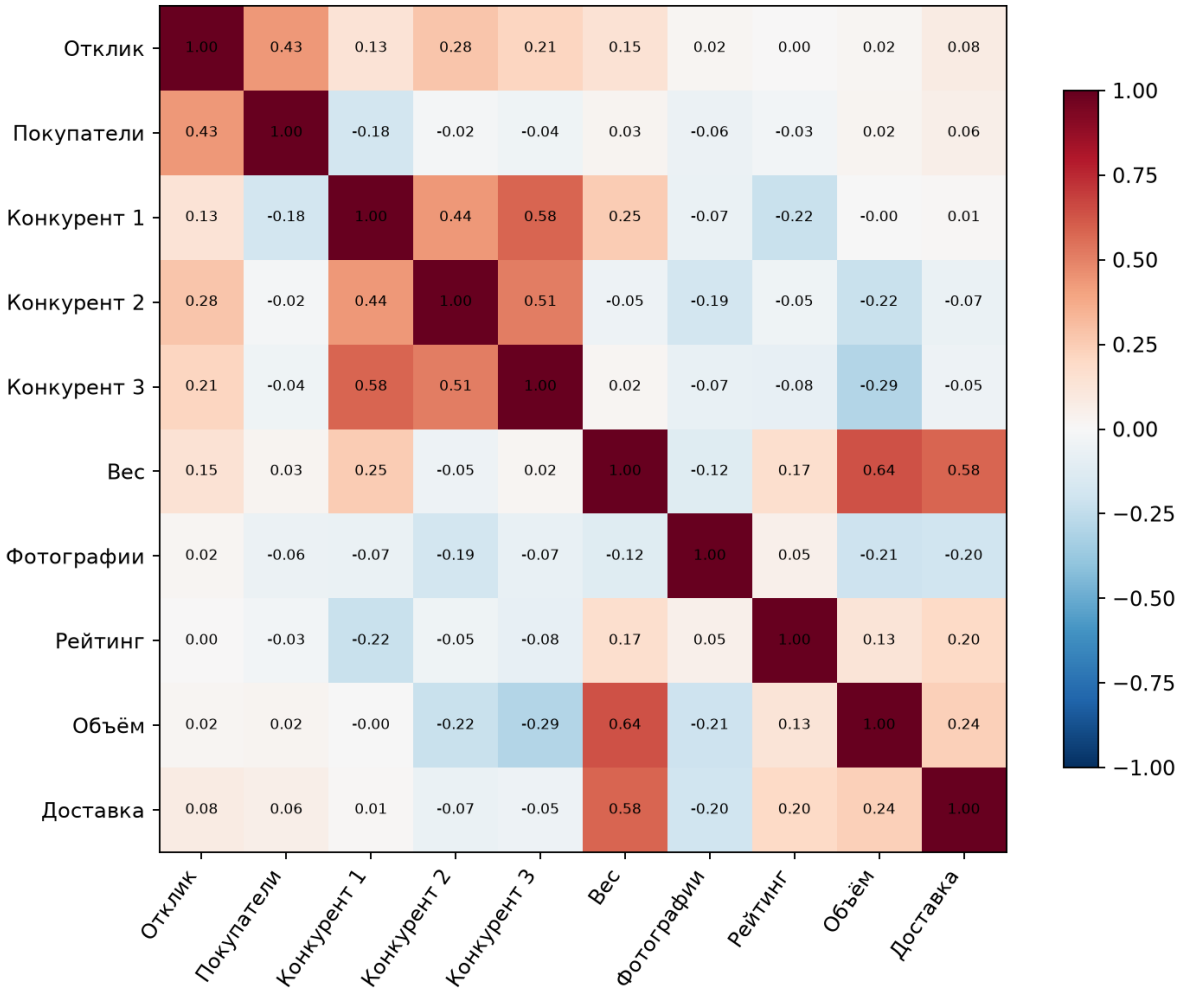


Рисунок 1.3 — Матрица корреляций на модельных шкалах

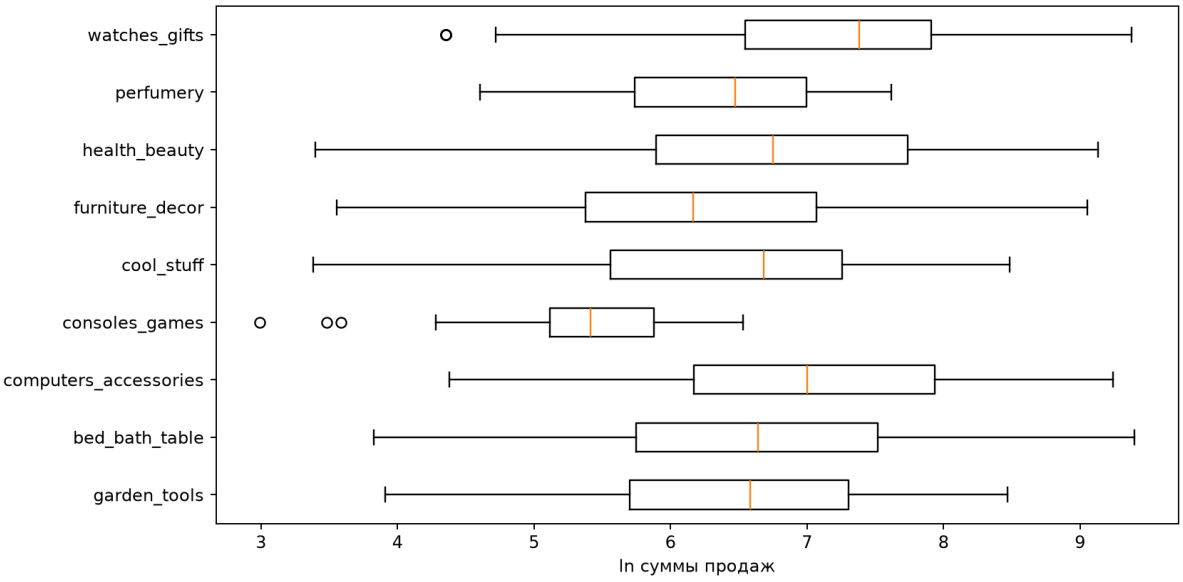


Рисунок 1.4 — Распределения логарифма суммы продаж по категориям

1.5 Исследовательские гипотезы

Основная гипотеза касается конкурентных цен:

$$H_0 : \gamma_1 = \gamma_2 = \gamma_3 = 0, \qquad H_1 : \text{хотя бы один коэффициент отличен от нуля.} \tag{1.3}$$

Здесь γ_j — коэффициент логарифма цены конкурента j в общей модели. Проверка относится к условной связи после учёта остальных факторов.

Дополнительно рассматриваются индивидуальные коэффициенты девяти числовых факторов, совместный вклад рейтинга, объёма и доставки, различия категорий и одна проверка нелинейности связи с покупателями. Уровень значимости принят равным 5%. Индивидуальные проверки образуют семейство из девяти гипотез, для которого применяется поправка Холма.

Направление связи не объявляется известным заранее. В частности, большая сумма продаж может сопровождать более дорогие товары и одновременно зависеть от количества продаж. Поэтому положительный коэффициент конкурентной цены не доказывает, что повышение собственной цены увеличит продажи. Гипотезы формулируют вопросы к данным, а не коммерческие рекомендации.

2 Множественная регрессия и оценка результатов

2.1 Построение и сравнение спецификаций

Общая линейная модель имеет вид [1, 2]

$$y_i = \beta_0 + \sum_{j=1}^{k} \beta_j x_{ij} + \varepsilon_i. \tag{2.1}$$

Отклик y_i в этой модели равен логарифму суммы продаж. Индекс i указывает на строку, j — на регрессор, а k задаёт их число без константы. Значение признака записано как x_{ij}, его коэффициент — как β_j; β_0 является свободным членом, ε_i — случайной ошибкой. Уравнение линейно по коэффициентам, хотя сами признаки могут быть логарифмами или индикаторами.

МНК минимизирует сумму квадратов отклонений:

$$\widehat{\boldsymbol{\beta}} = \operatorname*{argmin}_{\boldsymbol{\beta}} \sum_{i=1}^{n} (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 = (X^\top X)^{-1} X^\top \mathbf{y}. \tag{2.2}$$

$\boldsymbol{\beta}$ — вектор коэффициентов с константой, $\mathbf{x}_i$ — вектор факторов с единицей, X — матрица таких строк, $\mathbf{y}$ — вектор откликов. Знак $\top$ означает транспонирование, $^{-1}$ — обратную матрицу; $\arg\min$ обозначает значение аргумента, при котором достигается минимум. Формула справа требует полного столбцового ранга X. Шляпка обозначает оценку. Остаток $e_i = y_i - \widehat{y}_i$ вычисляется после оценивания и отличается от ненаблюдаемой ошибки ε_i.

Модель предполагает корректное описание условного среднего и отсутствие точной линейной зависимости факторов. Для интерпретации коэффициентов как несмещённых оценок условной зависимости требуется $E(\varepsilon_i \mid X) = 0$. Проверить это условие полностью по имеющимся данным невозможно: неучтённые свойства товара могут одновременно быть связаны с ценами и продажами. Кластерные стандартные ошибки такую проблему не устраняют.

Используются следующие модели:

- S1–S3: покупатели, один конкурент, вес и фотографии;
- M1: покупатели, все три конкурента, вес и фотографии;

- M2: M1 и восемь индикаторов категории;
- M3: M2, рейтинг, логарифм объёма и доставка.

По согласованному плану основное внимание уделяется M3: она позволяет рассмотреть девять числовых факторов при учёте категории. M2 нужна для сравнения с более коротким уравнением. Сопоставление этих моделей показывает отдельно, что даёт расширение для оценки связей и что — для предсказания.

Основная расширенная модель M3 записывается как

$$\begin{aligned}\ln T_i = \beta_0 + \beta_C \ln C_i + \sum_{j=1}^{3} \gamma_j \ln P_{ij} + \beta_W \ln W_i + \delta Q_i \\ + \theta_S S_i + \theta_V \ln V_i + \theta_L L_i + \sum_{h=1}^{8} \alpha_h D_{ih} + \varepsilon_i.\end{aligned} \tag{2.3}$$

T_i — сумма продаж; C_i — покупатели; P_{ij} — конкурентные цены; W_i — вес; Q_i — число фотографий; S_i — рейтинг `product_score`, не столбец `s`; V_i — объём; L_i — доставка. Индикатор D_{ih} равен единице для категории h и нулю иначе. База — `garden_tools`; α_h задаёт отличие от неё. Остальные греческие буквы — коэффициенты соответствующих факторов.

Во всех спецификациях используются одинаковые 676 строк. Ранги матриц равны числу коэффициентов; у M3 ранг равен 18. Полный ранг имеется и у оценённой кластерной ковариационной матрицы. Для оценки подгонки используются

$$R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2}, \qquad R^2_{adj} = 1 - (1 - R^2)\frac{n-1}{n-k-1}. \tag{2.4}$$

$\bar{y}$ — среднее логарифма отклика, $n = 676$, k — число регрессоров без константы; для M3 $k = 17$. Скорректированный показатель учитывает число параметров, но также характеризует подгонку на исходных данных, а не ошибку на новых товарах. В коде используются `OLS.fit`, `rsquared`, `rsquared_adj` [7].

При переходе от M1 к M2 скорректированный R^2 возрастает с 0,305 до 0,361. После добавления трёх факторов он достигает 0,379. Значение $R^2 = 0{,}395$ означает, что M3 описывает около 39,5% выборочного разброса

Таблица 2.1 — Подгонка моделей на общей выборке

Модель	Параметров	R^2	R^2_{adj}
S1	5	0,244	0,239
S2	5	0,303	0,299
S3	5	0,263	0,258
M1	7	0,311	0,305
M2	15	0,374	0,361
M3	18	0,395	0,379
M3 + месяцы	37	0,407	0,374

логарифма суммы продаж. Это не доля объяснённой причинности и не процент точных прогнозов.

Таблица 2.2 — Изменение оценок при расширении модели

Фактор	M1	M2	M3
Покупатели	0,550	0,690	0,686
Конкурент 1	0,024	0,173	0,195
Конкурент 2	0,594	0,329	0,252
Конкурент 3	0,224	0,415	0,447
Вес	0,152	0,370	0,314
Фотографии	0,100	0,103	0,126
Рейтинг	—	—	-0,029
Объём	—	—	0,335
Доставка	—	—	0,000105

В таблице оценок видно, что коэффициенты конкурентных цен меняются после включения категории. В частности, прежний вывод о втором конкуренте зависел от состава уравнения. В M3 ценовые различия рассматриваются уже с поправкой на категорию и остальные характеристики, поэтому результаты этой модели интерпретируются отдельно от M1.

2.2 Проверка коэффициентов и совместных гипотез

Для каждого числового фактора проверяется равенство его коэффициента нулю, $\beta_j = 0$. Оценка делится на стандартную ошибку, после чего используется t-проверка. Для трёх цен нужен другой расчёт: проверяется их одновременное равенство нулю. Здесь применяется критерий Вальда в F-форме, который учитывает ковариации коэффициентов. В обеих проверках используется одна кластерная оценка ковариационной матрицы.

Строки сгруппированы по товару, поскольку несколько его месячных продаж могут иметь общие причины отклонения от модели. Для вывода используются приближения t- и F-распределениями при независимости товарных групп. В выборке 52 группы; особенно осторожной интерпретации требуют редкие категории и возможная связь ошибок разных товаров. Нормальность исходных признаков для выбора этих проверок не требуется.

Наряду с p-value рассчитаны 95%-ные интервалы: они позволяют судить о размере связи и точности её оценки. Для них используются те же кластерные ошибки и t-квантиль. Девять отдельных проверок образуют семейство, в котором поправка Холма ограничивает риск хотя бы одного ложного отклонения. Она допускает зависимость между проверками при корректных исходных p-value. Для такого контроля требуется обоснованная модель ошибок; предшествующий выбор спецификаций на тех же данных сама поправка не учитывает [7].

Наблюдения одного товара могут иметь связанные ошибки. Применяется ковариационная оценка CR1 с группировкой по товару [7]:

$$\widehat{\mathcal{V}} = \frac{G}{G-1}\frac{n-1}{n-p}(X^\top X)^{-1}\left(\sum_{g=1}^{G} X_g^\top e_g e_g^\top X_g\right)(X^\top X)^{-1}. \tag{2.5}$$

$G = 52$ — число товарных групп; g — номер группы; X_g и e_g — матрица факторов и вектор остатков этой группы; $p = k + 1 = 18$ — число коэффициентов M3. Множители перед матрицами — поправка для конечной выборки. Диагональный элемент $\widehat{\mathcal{V}}_{jj}$ оценивает дисперсию коэффициента, а

$$\mathrm{SE}_{cluster}(\widehat{\beta}_j) = \sqrt{\widehat{\mathcal{V}}_{jj}} \tag{2.6}$$

есть его кластерная стандартная ошибка: мера неопределённости оценки, учитывающая сходство строк одного товара. Это не стандартное отклонение самого признака.

Для $H_0 : \beta_j = 0$ используется

$$t_j = \frac{\widehat{\beta}_j}{\mathrm{SE}_{cluster}(\widehat{\beta}_j)}, \quad p_j = 2\{1 - F_{t_{G-1}}(|t_j|)\}, \quad I_j = \widehat{\beta}_j \pm t_{0{,}975;G-1}\,\mathrm{SE}_{cluster}(\widehat{\beta}_j). \tag{2.7}$$

t_j — наблюдаемая статистика; $|t_j|$ — её модуль; $F_{t_{G-1}}$ — функция распределения Стьюдента с $G-1=51$ степенью свободы. Множитель 2 учитывает оба хвоста. Квантиль $t_{0{,}975;51}$ оставляет справа 2,5% вероятности. Знак $\pm$ задаёт нижнюю и верхнюю границы 95%-ного интервала I_j.

Это приближённые проверки для кластерной оценки, а не точное конечновыборочное t-распределение при любых зависимых ошибках. Кластеры предполагаются независимыми друг от друга; общие рыночные шоки могут нарушать это условие. В коде используются `get_robustcov_results` с `cov_type='cluster'`, `use_t=True`, `use_correction=True`, `df_correction=True`; интервалы получают через `conf_int`.

95%-ный доверительный интервал характеризует процедуру: при повторении выборок и выполнении предпосылок соответствующие интервалы должны накрывать истинный коэффициент примерно в 95% случаев. Он не означает, что после вычисления именно этот фиксированный коэффициент является случайным с вероятностью 95%.

p-value — вероятность при нулевой гипотезе получить статистику не менее экстремальную, чем наблюдаемая, в используемом приближении. Оно не равно вероятности истинности гипотезы. Большое p-value означает недостаток оснований для отклонения, но не доказывает отсутствия связи.

Для девяти индивидуальных коэффициентов применена поправка Холма [7]. Пусть $p_{(1)} \le \cdots \le p_{(m)}$ — упорядоченные исходные значения, $m=9$. Тогда

$$p_{(i)}^{Holm} = \min\left(1, \max_{1\le j\le i}\{(m-j+1)p_{(j)}\}\right). \tag{2.8}$$

i, j здесь обозначают позиции в сортировке. Скорректированные значения возвращаются в исходный порядок коэффициентов. Метод контролирует вероятность хотя бы одного ложного отклонения внутри семейства при корректных исходных p-value. Вычисление выполняет `multipletests(method='holm')`.

В основной М3 после поправки Холма значимы покупатели ($p_{Holm} < 0{,}001$) и вес ($p_{Holm} = 0{,}049$). Вывод по весу близок к выбранной границе. У третьего конкурента, фотографий и объёма исходные p-value меньше 0,05, но скорректированные больше 0,05. Их индивидуальные интервалы не содержат ноль, поскольку соответствующие нескорректированные двусто-

Таблица 2.3 — Коэффициенты М3: кластерные ошибки, p-value и индивидуальные интервалы

Фактор	$\widehat{\beta}$	SE	p	p_{Holm}	95%-ный ДИ
Покупатели	0,686	0,067	$< 0{,}001$	$< 0{,}001$	[0,552; 0,821]
Конкурент 1	0,195	0,144	0,182	0,728	[-0,094; 0,484]
Конкурент 2	0,252	0,277	0,367	1,000	[-0,303; 0,807]
Конкурент 3	0,447	0,207	0,035	0,211	[0,032; 0,862]
Вес	0,314	0,110	0,006	0,049	[0,094; 0,535]
Фотографии	0,126	0,060	0,041	0,211	[0,006; 0,246]
Рейтинг	-0,029	0,305	0,925	1,000	[-0,642; 0,584]
Объём	0,335	0,149	0,029	0,200	[0,036; 0,634]
Доставка	0,000105	0,011	0,993	1,000	[-0,022; 0,022]

ронние проверки отклоняют нулевые гипотезы. Решения после поправки Холма относятся к другому уровню контроля ошибки, поэтому противоречия здесь нет.

Совместная нулевая гипотеза записывается как $A\boldsymbol{\beta} = c$. Статистика Вальда в F-форме равна

$$F_W = \frac{1}{q}(A\widehat{\boldsymbol{\beta}} - c)^\top (A\widehat{\mathcal{V}}A^\top)^{-1}(A\widehat{\boldsymbol{\beta}} - c). \tag{2.9}$$

A — матрица ограничений, c — вектор их значений при нулевой гипотезе, q — число независимых ограничений. Для равенства коэффициентов нулю c — нулевой вектор. Проверяется невырожденность ковариации ограничений. Значение сопоставляется с $F(q, G-1)$, а p-value равно $1 - F_{q,G-1}(F_W)$, где $F_{q,G-1}$ — соответствующая функция распределения. В коде применяется `f_test` к кластерному результату.

Таблица 2.4 — Совместные проверки и проверка кривизны

Гипотеза	q	F	p
Цены конкурентов	3	4,100	0,011
Три новых фактора	3	1,843	0,151
Категории	8	7,007	$< 0{,}001$
Все факторы	17	20,534	$< 0{,}001$
Квадрат ln покупателей	1	1,669	0,202

В основной М3 конкурентные цены значимы совместно: $F_W(3, 51) = 4{,}100$, $p = 0{,}011$. Это согласуется с отсутствием убедительного выделения

каждого отдельного конкурента после поправки. Совместный вклад рейтинга, объёма и доставки не подтверждён: $F_W(3, 51) = 1{,}843$, $p = 0{,}151$. Категориальный блок значим в используемом приближении, но некоторые категории представлены двумя товарами, что ограничивает точность. Общий тест 17 коэффициентов также значим.

Для последовательного ответа на основной вопрос совместная проверка конкурентных цен сопоставлена и в предыдущих спецификациях: у M1 $F_W(3, 51) = 11{,}241$, $p < 0{,}001$; у M2 $F_W(3, 51) = 3{,}660$, $p = 0{,}018$. Таким образом, в используемом приближении совместная значимость сохраняется после добавления категории и трёх новых факторов, хотя оценки отдельных коэффициентов меняются. Это сравнение спецификаций, а не три независимых подтверждения результата. Оно ещё не учитывает общие календарные изменения; отдельная проверка с индикаторами месяцев приведена далее.

Основная проверка конкурентов рассматривается отдельно от семейства девяти индивидуальных проверок. Категории, дополнительный блок и кривизна — вспомогательные исследовательские проверки; поправка Холма не объявляется контролем ошибки по всей совокупности выполненных анализов.

2.3 Диагностика и устойчивость модели

Для регрессора j фактор инфляции дисперсии вычисляется как

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{2.10}$$

Для получения R_j^2 фактор j временно используется как отклик, а остальные факторы, включая индикаторы категории, — как объясняющие переменные. Если они хорошо восстанавливают этот столбец, VIF возрастает. Значения рассчитаны функцией `variance_inflation_factor`; по ним оценивается дублирование линейной информации в матрице факторов.

Наибольшее значение VIF, 7,158, получено для первого конкурента. Оно превышает принятый ориентир 5, хотя матрица сохраняет полный ранг. Первый конкурент оставлен в модели, поскольку сравнение всех трёх цен входит в вопрос исследования. Повышенный VIF затрудняет разделе-

Таблица 2.5 — VIF девяти факторов с учётом категории

Фактор	VIF
Покупатели	1,581
Конкурент 1	7,158
Конкурент 2	4,014
Конкурент 3	4,567
Вес	3,990
Фотографии	1,314
Рейтинг	1,404
Объём	3,365
Доставка	2,160

ние индивидуальных связей, однако одного этого показателя недостаточно, чтобы объяснить результаты проверок: индивидуальные решения зависят также от поправки Холма.

У веса и объёма VIF составляют 3,990 и 3,365. Чтобы оценить, насколько их информация пересекается, рассчитаны два дополнительных уравнения. Без объёма коэффициент веса возрастает с 0,314 до 0,398; без веса оценка объёма меняется с 0,335 до 0,451. При этом коэффициент покупателей остаётся около 0,687. Эти сопоставления показывают зависимость оценок физических свойств от присутствия друг друга; основной набор факторов по их результатам не менялся.

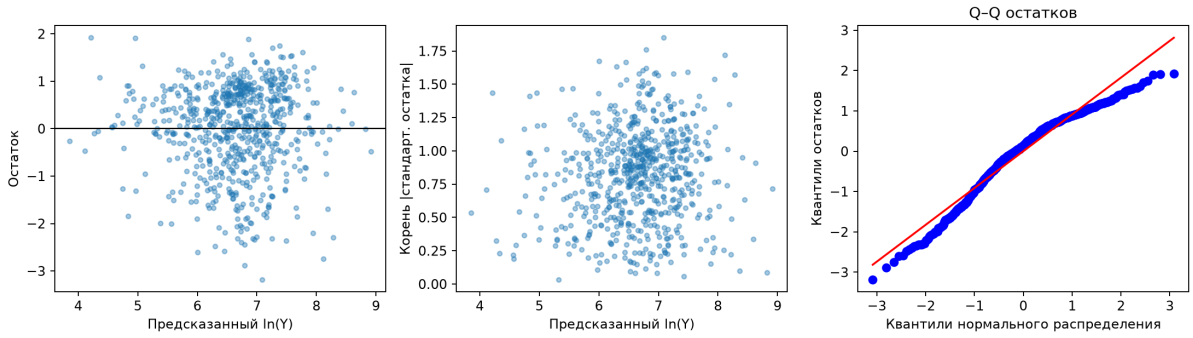


Рисунок 2.1 — Остатки МЗ, их разброс и Q–Q-диаграмма

На рисунке 2.1 заметна асимметрия остатков: отрицательный хвост длиннее положительного. Это видно и на Q–Q-диаграмме по отклонению от прямой. Разброс при разных расчётных уровнях продаж также неодинаков. Графики используются для описания этих особенностей; кластеризация была выбрана ранее из-за повторных записей товаров.

Средняя панель показывает $\sqrt{|e_i/s_e|}$. Остаток e_i делится на общее выборочное стандартное отклонение s_e с делителем $n-1$ (`e.std()`), затем берутся модуль и корень. Так удобнее сравнивать величину отклонений при разных предсказанных значениях. Индивидуальная поправка на положение строки в матрице факторов здесь не вводится; s_e также отличается от стандартной ошибки коэффициента.

Возможная кривизна связи с покупателями проверена добавлением к M3 члена $z_i = (\ln C_i - \overline{\ln C})^2$. Здесь $\overline{\ln C}$ — среднее логарифма покупателей, вычитаемое перед возведением в квадрат. Проверка нулевого коэффициента при z_i дала $F_W(1, 51) = 1{,}669$, $p = 0{,}202$. Такой результат не даёт оснований добавлять именно эту кривизну к основной M3; другие варианты нелинейности этим расчётом не проверялись.

Далее модель переоценивалась 52 раза. В каждом расчёте исключались все месяцы одного товара, а остальные данные сохранялись. В таблице 2.6 приведены наименьшая и наибольшая оценки каждого фактора. Это диапазоны результатов удаления товара; доверительный уровень 95% для них не задавался.

Таблица 2.6 — Изменение коэффициентов при исключении одного товара

Фактор	Полная оценка	Минимум	Максимум	Смен знака
Покупатели	0,686	0,661	0,722	0
Конкурент 1	0,195	0,093	0,255	0
Конкурент 2	0,252	0,157	0,528	0
Конкурент 3	0,447	0,317	0,572	0
Вес	0,314	0,235	0,375	0
Фотографии	0,126	0,064	0,146	0
Рейтинг	-0,029	-0,192	0,128	10
Объём	0,335	0,255	0,438	0
Доставка	0,000105	-0,004	0,007	27

Оценка покупателей лежит между 0,661 и 0,722 и во всех переоцениваниях положительна. Тот же знак сохраняется у трёх конкурентов, хотя коэффициент второго меняется заметно — от 0,157 до 0,528. Рейтинг меняет знак в 10 случаях, доставка — в 27; их направление чувствительно к отдельным товарам. Здесь сопоставлялись точечные оценки, поэтому сохранение знака ещё не означает сохранения статистической значимости.

Проверка охватывает удаление одного товара за раз; окончательная модель по-прежнему оценена на всей выборке.

Чувствительность к календарным эффектам

Отдельный источник изменений связан с календарём. Рыночные условия конкретного месяца могут одновременно отражаться на продажах и ценах конкурентов. Для проверки этого обстоятельства М3 дополнена 19 месячными индикаторами. Девять числовых факторов, категория, 676 строк и группировка ошибок по товару сохранены. Индикаторы различают все месяцы с января 2017 по август 2018, включая одинаковые сезонные месяцы разных лет. Базой выбран январь 2017 года.

Расширенная диагностическая спецификация имеет вид

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \sum_{m=2}^{20} \tau_m H_{im} + \varepsilon_i. \tag{2.11}$$

$y_i = \ln T_i$; $\mathbf{x}_i$ содержит все столбцы М3 с константой и категорией; H_{im} равен единице, если строка относится к календарному месяцу m, и нулю иначе; τ_m — общий сдвиг среднего логарифма отклика относительно базового месяца. Суммирование проводится по 19 небазовым месяцам. Модель имеет 37 коэффициентов; ранг матрицы и кластерной ковариации равен 37. Число товарных групп остаётся 52, для проверок используется то же приближение с 51 степенью свободы.

Таблица 2.7 — Чувствительность выводов к календарным эффектам

Спецификация	Параметров	p конкурентов	p_{Holm} веса
М3	18	0,011	0,049
М3 + месяцы	37	0,061	0,116

После включения месяцев совместный тест конкурентов даёт $F_W(3, 51) = 2{,}623$, $p = 0{,}061$; у основной М3 было $p = 0{,}011$. У веса p-value после Холма возрастает с 0,049 до 0,116. На уровне 5% обе гипотезы в календарной модели уже не отклоняются. При этом оценки трёх конкурентных цен остаются положительными. Меняется статистическое решение при выбранном пороге, а не устанавливается отсутствие свя-

зи. Различие самих коэффициентов двух моделей отдельным тестом не проверялось.

Календарный расчёт добавлен после замечания при рецензировании и представлен как дополнительная поисковая проверка. Его результат рассматривается вместе с основной М3. Более насыщенное уравнение содержит 37 коэффициентов при 52 товарных группах, а ошибки разных товаров по-прежнему могут быть связаны. Поэтому оснований объявлять его окончательно правильным также нет. Полные оценки с календарным контролем приведены в приложении Д. Предсказательное сравнение ниже относится к первоначальным М1–М3.

2.4 Интерпретация результатов

В модели с логарифмом фактора коэффициент b задаёт приблизительное процентное изменение результата при росте фактора на 1%. Для используемого далее шага 10% применяется точный пересчёт. Если исходный фактор увеличивается на долю a, отношение модельных геометрических средних равно $(1 + a)^b$, а изменение в процентах составляет

$$\Delta(a) = 100\{(1 + a)^b - 1\}\%. \tag{2.12}$$

Здесь $a = 0{,}1$ соответствует росту фактора на 10%, b — оценённый коэффициент. Для фактора в исходной шкале при увеличении на h единиц используется

$$\Delta(h) = 100\{\exp(bh) - 1\}\%. \tag{2.13}$$

exp — экспонента; $h = 1$ для фотографии и единицы доставки, $h = 0{,}1$ для рейтинга. Границы индивидуальных интервалов преобразуются той же монотонной функцией.

По оценке М3 увеличению показателя покупателей на 10% соответствует рост модельного геометрического среднего суммы продаж на 6,76% при фиксированных остальных признаках. Индивидуальный интервал — от 5,40 до 8,14%. Для веса тот же шаг даёт 3,04% с интервалом 0,90–5,23%. Последняя оценка получена при сравнении разных товаров; переносить её на результат изменения массы одного товара нельзя.

Таблица 2.8 — Процентная интерпретация коэффициентов М3

Фактор	Изменение фактора	Оценка, %	95%-ный ДИ, %
Покупатели	10%	6,761	[5,404; 8,135]
Конкурент 1	10%	1,874	[-0,895; 4,720]
Конкурент 2	10%	2,428	[-2,850; 7,994]
Конкурент 3	10%	4,353	[0,308; 8,561]
Вес	10%	3,039	[0,896; 5,228]
Фотографии	1	13,430	[0,563; 27,942]
Рейтинг	0.1	-0,289	[-6,220; 6,017]
Объём	10%	3,248	[0,348; 6,231]
Доставка	1	0,010	[-2,200; 2,271]

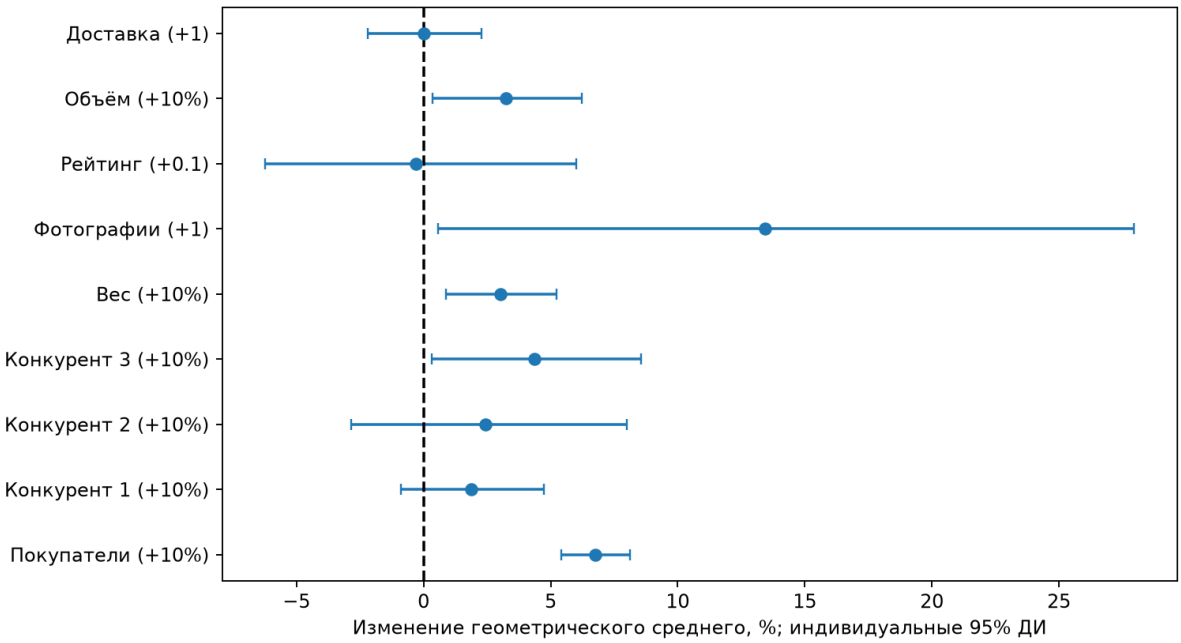


Рисунок 2.2 — Оценки относительных связей и индивидуальные 95%-ные интервалы

Для цены третьего конкурента шаг 10% даёт оценку изменения модельного геометрического среднего суммы продаж 4,35%. Индивидуальный вывод после Холма не подтверждается. В М3 обнаружена совместная связь блока цен, но календарная модель уже не даёт отклонения нулевой гипотезы на 5%. Совместная проверка относится к одновременному равенству трёх коэффициентов нулю; её результат не определяет конкретного конкурента. Для сравнения коэффициентов между собой потребовалась бы отдельная проверка их разности.

Оценки рейтинга и доставки малы по сравнению с их кластерными ошибками. В интервалах присутствует ноль, а при исключении товаров меняются знаки. В этой выборке их индивидуальные связи определяются неточно. Результат относится к данной модели и не переносится на роль рейтинга или доставки в торговле в целом.

Геометрическое среднее $\exp\{E(\ln T \mid X)\}$ отличается от арифметического $E(T \mid X)$. Прямое экспоненцирование предсказанного логарифма без поправки на распределение ошибки не даёт автоматически прогноз средней денежной суммы. Поэтому приведённые проценты относятся к логарифмической модели; прогнозы и ошибки далее оцениваются на её шкале.

2.5 Оценка качества предсказания

Для проверки предсказаний товары разделены на пять частей. Модель обучается на четырёх частях и предсказывает продажи пятой. Все месяцы одного товара относятся к одной части. Так проверяется перенос на товары, которых не было в обучении; случайное распределение отдельных строк оставило бы в обучении другие месяцы того же товара.

Сначала проверено стандартное разбиение GroupKFold [8]. Оно не обеспечило присутствия каждой категории в обучении всех частей. Поэтому использован заранее определённый резервный алгоритм: товары перемешиваются внутри категории с фиксированным `seed=20261030` и распределяются по частям с балансировкой числа товаров. Значения отклика в разбиении не используются. В проверочных частях получилось 11, 11, 10, 10 и 10 товаров; все категории представлены в соответствующем обучении.

Для каждой части модели заново оцениваются по остальным товарам. Сравниваются среднее обучающего логарифма отклика, М1, М2 и М3.

Категории кодируются одинаково, численные параметры регрессии оцениваются только на обучении. Пересечения товаров, полнота покрытия строк, представленность категорий и полный ранг обучающих матриц проверяются программно.

По объединённым предсказаниям вне обучения рассчитываются [8]

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \widehat{y}_i^{\,out})^2}, \qquad \mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \widehat{y}_i^{\,out}|. \tag{2.14}$$

$\widehat{y}_i^{\,out}$ — предсказание модели, не обучавшейся на товаре строки i; $n = 676$. RMSE сильнее реагирует на большие ошибки, MAE показывает среднюю абсолютную ошибку. Оба показателя измеряются в единицах натурального логарифма и не являются процентами. Каждая строка имеет одинаковый вес, поэтому товары с большим числом месяцев дают больший вклад.

Таблица 2.9 — Качество на исключённых товарах: шкала логарифма

Модель	RMSE	MAE	R^2	SD(RMSE)
Mean	1,199	0,982	-0,009	0,077
M1	1,043	0,853	0,238	0,079
M2	1,030	0,833	0,256	0,072
M3	1,033	0,836	0,252	0,100

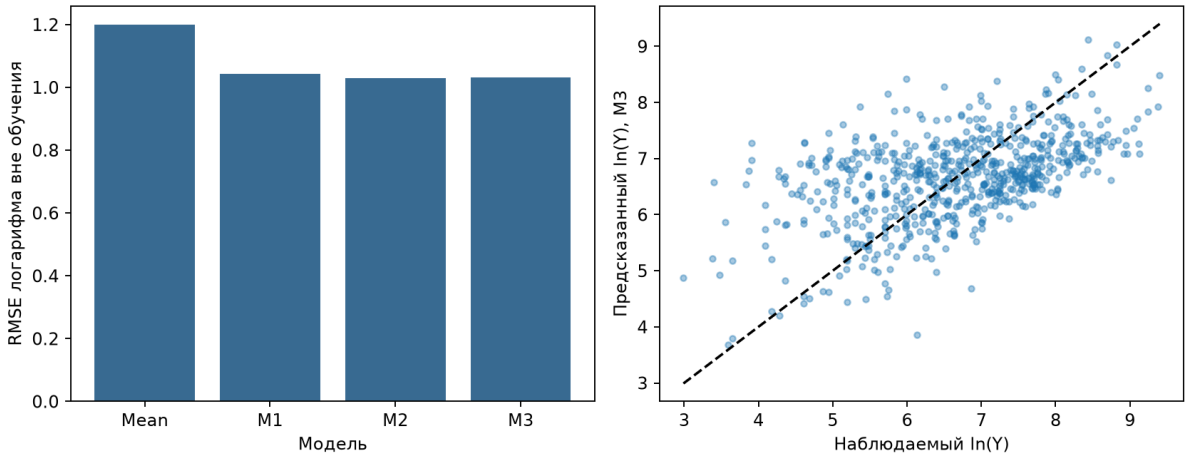


Рисунок 2.3 — Ошибка вне обучения и предсказания M3

У прогноза среднего RMSE равна 1,199, у M1 — 1,043, у M2 — 1,030, у M3 — 1,033. Все три регрессии дают меньшую ошибку, чем этот простой ориентир, на выбранном разбиении. M2 имеет немного меньшую ошибку,

чем М3, но разница мала и не представляется статистически доказанным превосходством. Добавление трёх факторов повысило подгонку на исходной выборке, однако не улучшило совокупные RMSE и MAE вне обучения.

Столбец SD(RMSE) содержит стандартное отклонение пяти ошибок частей. Обучающие наборы пересекаются, поэтому это описательная мера разброса, а не стандартная ошибка по пяти независимым экспериментам. Доверительные интервалы для разности качества по такой формуле не строятся. Коэффициент R^2 в таблице рассчитан по всем предсказаниям вне обучения, а не усреднением пяти отдельных значений. У прогноза среднего он отрицателен: в каждой части используется среднее только обучающих строк, которое может отличаться от общего среднего всей выборки, служащего ориентиром в знаменателе R^2. Совокупная ошибка характеризует только выбранное разбиение. Оно не гарантирует сохранения порядка моделей при другом разделении товаров. Проверка также не является полностью независимым подтверждением: общий подход выбран после предшествующего изучения того же набора данных.

Проверка относится к новым для обучения товарам уже известных категорий при известных признаках тех же исторических периодов. Она не является прогнозом будущего: будущие значения покупателей и конкурентных цен не заданы. Общие условия категории и месяца могут присутствовать в обеих частях. Результат не следует переносить на новые категории, другие рынки или будущие периоды без отдельной проверки.

ЗАКЛЮЧЕНИЕ

Исследование выполнено по 676 месячным наблюдениям для 52 товаров. Сначала проверены даты, пропуски, дубликаты и допустимость числовых значений. Все строки сохранены. Сопоставление `total_price` с ценой единицы и количеством позволило принять его за сумму месячных продаж. Одновременно выяснилось, что показатель покупателей общий для категории и месяца, а вес, объём, рейтинг и фотографии постоянны у каждого товара.

Распределение суммы продаж имеет правый хвост, поэтому для регрессии использован её логарифм. Парные корреляции показали положительную связь с покупателями и конкурентными ценами; сравнение категорий выявило различия ассортимента. Затем оценены модели с шестью факторами, с добавленной категорией и с расширением до девяти числовых факторов. Полная М3 содержит 18 коэффициентов, имеет $R^2 = 0{,}395$ и скорректированный $R^2 = 0{,}379$.

В основной М3 кластерный тест дал совместную значимость трёх конкурентных цен ($p = 0{,}011$). После Холма из девяти числовых факторов выделились покупатели и вес; отдельный конкурент не выделился. Добавление 19 календарных индикаторов изменило этот результат: совместное p-value конкурентов стало 0,061, а p-value веса после Холма — 0,116. Вывод на уровне 5% зависит от учёта времени. Поэтому положительные оценки конкурентных цен можно обсуждать как результат основной спецификации, указывая его календарную чувствительность.

Добавленный блок рейтинга, объёма и доставки не получил совместного подтверждения на уровне 5% ($p = 0{,}151$). Диагностика выявила повышенный VIF у первого конкурента и асимметрию остатков. Проверка квадрата логарифма покупателей не дала основания для этой конкретной нелинейности. При поочерёдном исключении товаров знак покупателей оставался положительным, а рейтинг и доставка меняли знак. Таким образом, чувствительность к составу выборки различается для разных оценок.

На исключённых товарах RMSE логарифма составила 1,199 для прогноза среднего, 1,030 для М2 и 1,033 для М3. Добавление рейтинга, объёма и доставки повысило подгонку исходных данных, но не снизило ошибку на

выбранном разбиении. Статистическое превосходство M2 над M3 не проверялось; разница их ошибок мала. Расширение использовано для изучения связей, а его предсказательная польза по этой проверке не подтверждена.

При оценке результатов существенны небольшой набор из 52 товаров, редкие категории и неполное описание исходных агрегатов. Для пограничного результата веса ($p_{Holm} = 0{,}049$) эти ограничения особенно важны. Кластеризация учитывает зависимость месяцев одного товара, но предполагает независимость ошибок разных товаров. Общие условия рынка или категории могут нарушать это предположение; совпадение покупателей внутри категории и месяца указывает на общий уровень измерения, хотя само по себе не устанавливает зависимость ошибок. Поэтому рассчитанные p-value и интервалы относятся к принятой схеме ошибок.

Индивидуальные эффекты товаров в уравнение не включались. Календарные эффекты исследованы дополнительно, однако они не заменяют проверку межтоварной зависимости. Результаты позволяют описать условные связи в имеющемся наборе; для причинных выводов, назначения цены и прогноза будущих продаж нужны другие данные и проверки.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 Кобзарь А.И. Прикладная математическая статистика. — М.: Физматлит, 2006.

2 Wooldridge J.M. Introductory Econometrics: A Modern Approach. — 6th ed. — Cengage Learning, 2016.

3 Retail Price Optimization. Набор данных. Kaggle. URL: https://www.kaggle.com/datasets/suddharshan/retail-price-optimization (дата обращения: 30.10.2026).

4 NumPy Developers. NumPy documentation: Linear algebra. URL: https://numpy.org/doc/stable/reference/routines.linalg.html (дата обращения: 30.10.2026).

5 pandas Developers. pandas documentation. URL: https://pandas.pydata.org/docs/ (дата обращения: 30.10.2026).

6 SciPy Developers. Statistical functions: scipy.stats. URL: https://docs.scipy.org/doc/scipy/reference/stats.html (дата обращения: 30.10.2026).

7 statsmodels Developers. Linear Regression; Robust Covariance; Multiple Tests. URL: https://www.statsmodels.org/stable/ (дата обращения: 30.10.2026).

8 scikit-learn Developers. GroupKFold; Regression metrics. URL: https://scikit-learn.org/stable/ (дата обращения: 30.10.2026).

ПРИЛОЖЕНИЕ А

Подготовка данных и предварительный анализ

Код приложений выполняется последовательно в одном сеансе Python из каталога проекта. Это те же вычислительные блоки, из которых сформирован ноутбук `science_work_simple.ipynb`. Отдельные листинги используют переменные предыдущих блоков. Полный скрипт — `analysis_retail.py`; зависимости перечислены в `requirements.txt`.

```
from pathlib import Path
import hashlib
import json
import importlib.metadata
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
from scipy import stats
from statsmodels.stats.multitest import multipletests
from statsmodels.stats.outliers_influence import variance_inflation_factor
from sklearn.model_selection import GroupKFold
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from IPython.display import display

ROOT = Path.cwd()
if not (ROOT / 'retail_price.csv').exists():
    ROOT = ROOT / 'scienceWork'
assert (ROOT / 'retail_price.csv').exists(), 'Run from the project directory'
for folder in ['results', 'figures', 'report_tables', 'appendix']:
    (ROOT / folder).mkdir(exist_ok=True)
plt.rcParams.update({'font.family': 'DejaVu Sans', 'font.size': 10})
SEED = 20261030

def table(name, data):
    data.to_csv(ROOT / 'results' / (name + '.csv'), index=False)
    display(data.round(5))

def figure(name):
    plt.tight_layout()
    plt.savefig(ROOT / 'figures' / (name + '.png'), dpi=170,
                bbox_inches='tight')
    plt.show()
    plt.close()
```

```
raw = pd.read_csv(ROOT / 'retail_price.csv')
df = raw.copy()
df['date'] = pd.to_datetime(df['month_year'], format='%d-%m-%Y')
log_fields = ['total_price', 'customers', 'comp_1', 'comp_2', 'comp_3',
              'product_weight_g', 'volume']
checks = {
    'rows': len(df), 'products': df.product_id.nunique(),
    'categories': df.product_category_name.nunique(),
    'months': df.date.nunique(), 'missing': int(raw.isna().sum().sum()),
    'duplicates': int(raw.duplicated().sum()),
    'duplicate_product_month': int(df.duplicated(['product_id', 'date']).sum()),
    'nonpositive_log_values': int((df[log_fields] <= 0).sum().sum()),
    'negative_freight': int((df.freight_price < 0).sum()),
    'zero_freight': int((df.freight_price == 0).sum()),
    'calendar_mismatch': int(((df.date.dt.month != df.month) |
                              (df.date.dt.year != df.year)).sum()),
}
for name in ['missing', 'duplicates', 'duplicate_product_month',
             'nonpositive_log_values', 'negative_freight', 'calendar_mismatch']:
    assert checks[name] == 0, (name, checks[name])
assert np.isfinite(df.select_dtypes('number')).all().all()
```

```
assert df.groupby('product_id').product_category_name.nunique().max() == 1
relative_gap = abs(df.total_price - df.unit_price * df.qty) / df.total_price
checks['identity_within_0_3_percent'] = int((relative_gap < 0.003).sum())
checks['identity_max_gap'] = float(relative_gap.max())
checks['category_month_customer_max_unique'] = int(df.groupby(
    ['product_category_name', 'date']).customers.nunique().max())
checks['start'] = str(df.date.min().date())
checks['end'] = str(df.date.max().date())
for col in log_fields:
    df['ln_' + col] = np.log(df[col])
BASE = ['ln_customers', 'ln_comp_1', 'ln_comp_2', 'ln_comp_3',
        'ln_product_weight_g', 'product_photos_qty']
EXTRA = ['product_score', 'ln_volume', 'freight_price']
FACTORS = BASE + EXTRA
LABELS = dict(zip(FACTORS, ['Покупатели', 'Конкурент 1', 'Конкурент 2',
    'Конкурент 3', 'Вес', 'Фотографии', 'Рейтинг', 'Объём', 'Доставка']))
category_counts = df.groupby('product_category_name').agg(
    rows=('product_id', 'size'), products=('product_id', 'nunique'),
    median_total=('total_price', 'median')).reset_index()
# Ties are resolved lexicographically, without using the outcome.
base_category = category_counts.sort_values(
    ['products', 'product_category_name'], ascending=[False, True]).iloc[0, 0]
categories = [base_category] + sorted(set(df.product_category_name) - {base_category})
DUMMIES = ['cat_' + c for c in categories[1:]]

def design(data, factors, categorical=False):
    X = data[factors].astype(float).copy()
    if categorical:
        for cat, col in zip(categories[1:], DUMMIES):
            X[col] = (data.product_category_name == cat).astype(float)
    return sm.add_constant(X, has_constant='add')

checks['base_category'] = base_category
print(json.dumps(checks, ensure_ascii=False, indent=2))
table('categories', category_counts)
audit = []
for c in raw.columns:
    row = {'column': c, 'dtype': str(raw[c].dtype),
           'missing': int(raw[c].isna().sum()), 'unique': raw[c].nunique()}
    if pd.api.types.is_numeric_dtype(raw[c]):
        row.update(min=float(raw[c].min()), max=float(raw[c].max()),
            varying_products=int((df.groupby('product_id')[c].nunique() > 1).sum()))
    audit.append(row)
table('column_audit', pd.DataFrame(audit))
```

```
original = log_fields + ['product_photos_qty', 'product_score', 'freight_price']
desc = df[original].describe().T.reset_index(names='variable')
table('descriptive', desc)
pearson = df[['ln_total_price'] + FACTORS].corr()
spearman = df[['ln_total_price'] + FACTORS].corr(method='spearman')
pearson.to_csv(ROOT / 'results' / 'pearson.csv')
spearman.to_csv(ROOT / 'results' / 'spearman.csv')
table('target_correlations', pd.DataFrame({'factor': FACTORS,
    'pearson': pearson.loc[FACTORS, 'ln_total_price'].values,
    'spearman': spearman.loc[FACTORS, 'ln_total_price'].values}))
fig, ax = plt.subplots(1, 2, figsize=(10, 3.8))
for a, c, title in zip(ax, ['total_price', 'ln_total_price'],
                       ['Суммарная стоимость продаж', 'Логарифм суммы продаж']):
    a.hist(df[c], bins=30, color='#386a91', edgecolor='white')
    a.set(xlabel=title, ylabel='Число наблюдений')
figure('distributions')
fig, ax = plt.subplots(2, 2, figsize=(10, 7))
for a, c in zip(ax.flat, BASE[:4]):
    a.scatter(df[c], df.ln_total_price, s=12, alpha=.4)
    a.set(xlabel='ln: ' + LABELS[c], ylabel='ln суммы продаж')
figure('relationships')
fig, ax = plt.subplots(figsize=(9, 7))
im = ax.imshow(pearson, cmap='RdBu_r', vmin=-1, vmax=1)
labels = ['Отклик'] + [LABELS[c] for c in FACTORS]
ax.set_xticks(range(10), labels, rotation=55, ha='right')
ax.set_yticks(range(10), labels)
for i in range(10):
    for j in range(10):
        ax.text(j, i, f'{pearson.iloc[i,j]:.2f}', ha='center', va='center', fontsize=7)
fig.colorbar(im, ax=ax, shrink=.8)
figure('correlations')
fig, ax = plt.subplots(figsize=(10, 5))
ax.boxplot([df.loc[df.product_category_name == c, 'ln_total_price']
```

```
34              for c in categories], tick_labels=categories, orientation='horizontal')
35  ax.set_xlabel('ln суммы продаж')
36  figure('categories')
```

ПРИЛОЖЕНИЕ Б

Модели и проверка гипотез

```
def fit_cluster(X, data):
    assert np.linalg.matrix_rank(X) == X.shape[1], 'Rank deficient design'
    ols = sm.OLS(data.ln_total_price, X).fit()
    robust = ols.get_robustcov_results(cov_type='cluster',
        groups=data.product_id.to_numpy(), use_correction=True,
        df_correction=True, use_t=True)
    return ols, robust

specs = {f'S{j}': (['ln_customers', f'ln_comp_{j}',
    'ln_product_weight_g', 'product_photos_qty'], False) for j in [1, 2, 3]}
specs.update({'M1': (BASE, False), 'M2': (BASE, True), 'M3': (FACTORS, True)})
fits, matrices, fit_rows = {}, {}, []
for name, (factors, categorical) in specs.items():
    X = design(df, factors, categorical)
    ols, robust = fit_cluster(X, df)
    fits[name] = (ols, robust)
    matrices[name] = X
    fit_rows.append({'model': name, 'n': int(ols.nobs), 'parameters': X.shape[1],
        'rank': np.linalg.matrix_rank(X), 'cov_rank': np.linalg.matrix_rank(robust.cov_params()),
        'r2': ols.rsquared, 'adjusted_r2': ols.rsquared_adj})
# Sensitivity only: 19 calendar year-month indicators, base January 2017.
# Keep the same rows, factors, CR1 correction and product clusters.
month_labels = df.date.dt.to_period('M').astype(str)
month_indicators = pd.get_dummies(month_labels, prefix='time', drop_first=True,
                                  dtype=float)
assert month_indicators.shape[1] == 19
Xtime = pd.concat([matrices['M3'], month_indicators], axis=1)
fits['M3_time'] = fit_cluster(Xtime, df)
matrices['M3_time'] = Xtime
ols_time, robust_time = fits['M3_time']
fit_rows.append({'model': 'M3_time', 'n': int(ols_time.nobs),
    'parameters': Xtime.shape[1], 'rank': np.linalg.matrix_rank(Xtime),
    'cov_rank': np.linalg.matrix_rank(robust_time.cov_params()),
    'r2': ols_time.rsquared, 'adjusted_r2': ols_time.rsquared_adj})
table('model_comparison', pd.DataFrame(fit_rows))

coef_rows = []
for name, (ols, r) in fits.items():
    ci = r.conf_int()
    for j, col in enumerate(matrices[name].columns):
        coef_rows.append({'model': name, 'term': col, 'coef': r.params[j],
            'se': r.bse[j], 't': r.tvalues[j], 'p': r.pvalues[j],
            'low': ci[j,0], 'high': ci[j,1]})
coefs = pd.DataFrame(coef_rows)
coefs.to_csv(ROOT / 'results' / 'all_coefficients.csv', index=False)
main = coefs[(coefs.model == 'M3') & coefs.term.isin(FACTORS)].copy()
main['p_holm'] = multipletests(main.p, method='holm')[1]
main['holm_reject'] = main.p_holm < .05
table('main_coefficients', main)
time_coefficients = coefs[(coefs.model == 'M3_time') & coefs.term.isin(FACTORS)].copy()
time_coefficients['p_holm'] = multipletests(time_coefficients.p, method='holm')[1]
time_coefficients['holm_reject'] = time_coefficients.p_holm < .05
table('time_coefficients', time_coefficients)


# Reject singular restrictions rather than silently changing degrees of freedom.
def joint(model, cols, label):
    ols, r = fits[model]
    names = list(matrices[model].columns)
    A = np.eye(len(names))[[names.index(c) for c in cols]]
    rank = np.linalg.matrix_rank(A @ r.cov_params() @ A.T)
    if rank != len(cols):
        return dict(test=label, model=model, q=len(cols), rank=rank,
                    F=np.nan, p=np.nan, df_denom=np.nan)
    t = r.f_test(A)
    return dict(test=label, model=model, q=len(cols), rank=rank,
        F=float(t.fvalue), p=float(t.pvalue), df_denom=float(t.df_denom))

```

```
joint_rows = [joint('M3', BASE[1:4], 'competitors'),
    joint('M3', EXTRA, 'additional_block'),
    joint('M3', DUMMIES, 'categories'),
    joint('M3', FACTORS + DUMMIES, 'overall')]
Xq = matrices['M3'].copy()
Xq['customers_sq'] = (df.ln_customers - df.ln_customers.mean()) ** 2
matrices['M3q'] = Xq
fits['M3q'] = fit_cluster(Xq, df)
joint_rows.append(joint('M3q', ['customers_sq'], 'curvature'))
table('joint_tests', pd.DataFrame(joint_rows))
# Additional exploratory check; no search over alternative time specifications.
time_test = joint('M3_time', BASE[1:4], 'competitors_time')
table('time_joint_test', pd.DataFrame([time_test]))
time_rows = []
for model, coefficients, test in [
        ('M3', main, joint_rows[0]), ('M3_time', time_coefficients, time_test)]:
    time_rows.append({'model': model, 'n': len(df),
        'parameters': matrices[model].shape[1],
        'month_indicators': 19 if model == 'M3_time' else 0,
        'competitors_F': test['F'], 'competitors_p': test['p'],
        'weight_p_holm': float(coefficients.set_index('term').loc[
            'ln_product_weight_g', 'p_holm'])})
table('time_sensitivity', pd.DataFrame(time_rows))
print('Calendar check: the competitors result depends on specification. '
      'Failing to reject at 5% is not proof of no relationship.')
```

ПРИЛОЖЕНИЕ B

Диагностика и интерпретация

```
X = matrices['M3']
vif = pd.DataFrame({'term': FACTORS, 'vif': [variance_inflation_factor(
    X.to_numpy(), X.columns.get_loc(c)) for c in FACTORS]})
table('vif', vif)
ols, robust = fits['M3']
e = ols.resid
fig, ax = plt.subplots(1, 3, figsize=(13, 3.8))
ax[0].scatter(ols.fittedvalues, e, s=12, alpha=.4)
ax[0].axhline(0, color='black', lw=1)
ax[0].set(xlabel='Предсказанный ln(Y)', ylabel='Остаток')
ax[1].scatter(ols.fittedvalues, np.sqrt(abs(e / e.std())), s=12, alpha=.4)
ax[1].set(xlabel='Предсказанный ln(Y)', ylabel='Корень |стандарт. остатка|')
stats.probplot(e, dist='norm', plot=ax[2])
ax[2].set(title='Q-Q остатков', xlabel='Квантили нормального распределения',
          ylabel='Квантили остатков')
figure('diagnostics')
loo = []
for product in sorted(df.product_id.unique()):
    subset = df.loc[df.product_id != product]
    Xsub = design(subset, FACTORS, True)
    model, _ = fit_cluster(Xsub, subset)
    for term in FACTORS:
        loo.append({'removed_product': product, 'term': term,
                    'coef': model.params[term]})
loo = pd.DataFrame(loo)
loo.to_csv(ROOT / 'results' / 'leave_one_product_out.csv', index=False)
sensitivity = loo.groupby('term').coef.agg(['min','max']).reindex(FACTORS)
sensitivity['full'] = main.set_index('term').coef
sensitivity['sign_changes'] = [int((np.sign(loo.loc[loo.term == c, 'coef']) !=
    np.sign(sensitivity.loc[c, 'full'])).sum()) for c in FACTORS]
table('sensitivity', sensitivity.reset_index())
variants = []
for omit in ['ln_volume', 'ln_product_weight_g']:
    model, r = fit_cluster(design(df, [c for c in FACTORS if c != omit], True), df)
    for j, term in enumerate(model.model.exog_names):
        if term in FACTORS:
            variants.append({'omitted': omit, 'term': term,
                'coef': r.params[j], 'low': r.conf_int()[j,0], 'high': r.conf_int()[j,1]})
table('weight_volume_sensitivity', pd.DataFrame(variants))
```

```
steps = {c: np.log(1.1) if c.startswith('ln_') else 1 for c in FACTORS}
steps['product_score'] = .1
effects = main[['term']].copy()
for source, target in [('coef','percent'), ('low','low'), ('high','high')]:
    effects[target] = [100 * np.expm1(row[source] * steps[row.term])
                       for _, row in main.iterrows()]
effects['step'] = ['10%' if c.startswith('ln_') else
                   ('0.1' if c == 'product_score' else '1') for c in FACTORS]
table('effects', effects)
fig, ax = plt.subplots(figsize=(9, 5))
ax.errorbar(effects.percent, range(9),
    xerr=[effects.percent-effects.low, effects.high-effects.percent], fmt='o', capsize=3)
ax.axvline(0, color='black', ls='--')
ax.set_yticks(range(9), [LABELS[c] + ' (+' + step + ')'
                         for c, step in zip(effects.term, effects.step)])
ax.set_xlabel('Изменение геометрического среднего, %; индивидуальные 95% ДИ')
figure('effects')
```

ПРИЛОЖЕНИЕ Г

Качество предсказания и воспроизводимость

```
splits = list(GroupKFold(n_splits=5).split(df, groups=df.product_id))
def coverage_ok(splits):
    return all(set(df.iloc[tr].product_category_name) == set(categories)
               for tr, te in splits)
fold_method = 'GroupKFold'
if not coverage_ok(splits):
    fold_method = 'category_balanced_product_folds'
    products = df[['product_id', 'product_category_name']].drop_duplicates()
    rng = np.random.default_rng(SEED)
    assignment, loads = {}, np.zeros(5, dtype=int)
    for cat in sorted(categories):
        ids = products.loc[products.product_category_name == cat, 'product_id'].to_numpy()
        ids = rng.permutation(np.sort(ids))
        for start in range(0, len(ids), 5):
            order = np.argsort(loads, kind='stable')
            for product, fold in zip(ids[start:start+5], order):
                assignment[product] = int(fold)
                loads[fold] += 1
    fold_vector = df.product_id.map(assignment).to_numpy()
    splits = [(np.where(fold_vector != f)[0], np.where(fold_vector == f)[0])
              for f in range(5)]
assert coverage_ok(splits)
oof = pd.DataFrame({'product_id': df.product_id, 'observed': df.ln_total_price,
                    'fold': -1})
fold_rows = []
for fold, (tr, te) in enumerate(splits):
    train, test = df.iloc[tr], df.iloc[te]
    assert set(train.product_id).isdisjoint(set(test.product_id))
    assert len(te) > 0
    oof.loc[te, 'fold'] = fold
    preds = {'Mean': np.repeat(train.ln_total_price.mean(), len(te))}
    for name in ['M1', 'M2', 'M3']:
        factors, categorical = specs[name]
        Xtrain = design(train, factors, categorical)
        assert np.linalg.matrix_rank(Xtrain) == Xtrain.shape[1]
        fitted = sm.OLS(train.ln_total_price, Xtrain).fit()
        preds[name] = fitted.predict(design(test, factors, categorical))
    for name, pred in preds.items():
        oof.loc[te, name] = np.asarray(pred)
        fold_rows.append({'fold': fold, 'model': name, 'test_rows': len(te),
            'test_products': test.product_id.nunique(),
            'rmse': np.sqrt(mean_squared_error(test.ln_total_price, pred)),
            'mae': mean_absolute_error(test.ln_total_price, pred)})
assert (oof.fold >= 0).all() and not oof.isna().any().any()
assert oof.groupby('product_id').fold.nunique().max() == 1
oof.to_csv(ROOT / 'results' / 'oof_predictions.csv', index=False)
fold_metrics = pd.DataFrame(fold_rows)
fold_metrics.to_csv(ROOT / 'results' / 'fold_metrics.csv', index=False)
cv = pd.DataFrame([{'model': name,
    'rmse': np.sqrt(mean_squared_error(oof.observed, oof[name])),
    'mae': mean_absolute_error(oof.observed, oof[name]),
    'r2': r2_score(oof.observed, oof[name]),
    'fold_rmse_sd': fold_metrics.loc[fold_metrics.model == name, 'rmse'].std()}
    for name in ['Mean', 'M1', 'M2', 'M3']])
table('cv_metrics', cv)
print('Fold allocation:', fold_method)
fig, ax = plt.subplots(1, 2, figsize=(10, 4))
ax[0].bar(cv.model, cv.rmse, color='#386a91')
ax[0].set(ylabel='RMSE логарифма вне обучения', xlabel='Модель')
ax[1].scatter(oof.observed, oof.M3, s=12, alpha=.4)
bounds = [min(oof.observed.min(), oof.M3.min()), max(oof.observed.max(), oof.M3.max())]
ax[1].plot(bounds, bounds, 'k--')
ax[1].set(xlabel='Наблюдаемый ln(Y)', ylabel='Предсказанный ln(Y), M3')
figure('validation')
```

```
r = fits['M3'][1]
np.testing.assert_allclose(r.pvalues, 2 * stats.t.sf(abs(r.tvalues), 51))
```

```
np.testing.assert_allclose(r.conf_int()[:,0], r.params-stats.t.ppf(.975,51)*r.bse)
X = matrices['M3'].to_numpy()
resid = np.asarray(fits['M3'][0].resid)
bread = np.linalg.inv(X.T @ X)
meat = np.zeros_like(bread)
for product in df.product_id.unique():
    idx = (df.product_id == product).to_numpy()
    score = X[idx].T @ resid[idx]
    meat += np.outer(score, score)
n, p = X.shape
g = df.product_id.nunique()
manual_cov = (g/(g-1))*((n-1)/(n-p))*bread @ meat @ bread
np.testing.assert_allclose(manual_cov, r.cov_params(), rtol=1e-6, atol=1e-8)
manual_beta = np.linalg.lstsq(X, df.ln_total_price, rcond=None)[0]
np.testing.assert_allclose(manual_beta, r.params, rtol=1e-8, atol=1e-8)
manifest = {'checks': checks, 'seed': SEED, 'fold_method': fold_method,
    'time_sensitivity': {'reference_month': str(month_labels.min()),
                         'month_indicators': month_indicators.shape[1]},
    'sha256': hashlib.sha256((ROOT/'retail_price.csv').read_bytes()).hexdigest(),
    'versions': {p: importlib.metadata.version(p) for p in
                 ['numpy','pandas','scipy','statsmodels','scikit-learn']},
    'validated': ['OLS coefficients', 'cluster CR1 covariance', 't p-values',
                  'confidence intervals', 'group separation', 'category coverage',
                  'full rank training matrices', 'complete OOF predictions']}
(ROOT/'results'/'manifest.json').write_text(json.dumps(manifest, ensure_ascii=False, indent=2))
print('Completed:', json.dumps(manifest, ensure_ascii=False, indent=2))
```

ПРИЛОЖЕНИЕ Д

Дополнительные оценки

База — `garden_tools`. Интервалы индивидуальные кластерные; редкие категории представлены лишь двумя товарами, поэтому оценки требуют осторожности. Константа и полная таблица всех коэффициентов сохранены в `results/all_coefficients.csv`.

Категория	$\widehat{\alpha}$	SE	95%-ный ДИ
bed_bath_table	0,901	0,331	[0,237; 1,565]
computers_accessories	1,355	0,374	[0,605; 2,105]
consoles_games	2,150	0,375	[1,398; 2,903]
cool_stuff	0,341	0,294	[-0,249; 0,931]
furniture_decor	0,448	0,319	[-0,192; 1,089]
health_beauty	1,360	0,419	[0,518; 2,201]
perfumery	1,946	0,399	[1,145; 2,747]
watches_gifts	0,898	0,415	[0,065; 1,731]

Девять факторов при календарном контроле

М3 дополнена 19 индикаторами месяцев. Интервалы индивидуальные; Холм применён к девяти числовым факторам.

Фактор	$\widehat{\beta}$	SE	p	p_{Holm}	95%-ный ДИ
Покупатели	0,759	0,096	$<$ 0,001	$<$ 0,001	[0,566; 0,952]
Конкурент 1	0,211	0,141	0,140	0,682	[-0,072; 0,495]
Конкурент 2	0,194	0,272	0,479	1,000	[-0,352; 0,740]
Конкурент 3	0,324	0,214	0,136	0,682	[-0,106; 0,754]
Вес	0,288	0,114	0,015	0,116	[0,060; 0,517]
Фотографии	0,134	0,061	0,034	0,202	[0,011; 0,257]
Рейтинг	-0,059	0,305	0,847	1,000	[-0,672; 0,554]
Объём	0,346	0,147	0,022	0,155	[0,052; 0,641]
Доставка	0,004	0,012	0,721	1,000	[-0,020; 0,028]